

CONESCAPANHONDURAS2025paper99.pdf

 Institute of Electrical and Electronics Engineers (IEEE)

Document Details

Submission ID

trn:oid:::14348:477757685

Submission Date

Jul 31, 2025, 10:43 PM CST

Download Date

Aug 12, 2025, 2:57 PM CST

File Name

CONESCAPANHONDURAS2025paper99.pdf

File Size

509.4 KB

4 Pages




2,306 Words

13,075 Characters

16% Overall Similarity

The combined total of all matches, including overlapping sources, for each database.

Top Sources

- 15%  Internet sources
- 3%  Publications
- 0%  Submitted works (Student Papers)

Integrity Flags




0 Integrity Flags for Review

No suspicious text manipulations found.

Our system's algorithms look deeply at a document for any inconsistencies that would set it apart from a normal submission. If we notice something strange, we flag it for you to review.

A Flag is not necessarily an indicator of a problem. However, we'd recommend you focus your attention there for further review.

Top Sources

- 15%  Internet sources
- 3%  Publications
- 0%  Submitted works (Student Papers)

Top Sources

The sources with the highest number of matches within the submission. Overlapping sources will not be displayed.

1	Internet	repositorio.unibe.edu.ec	4%
2	Internet	scielo.senescyt.gob.ec	4%
3	Internet	revistas.ucv.edu.pe	3%
4	Internet	www.researchgate.net	<1%
5	Internet	github.com	<1%
6	Internet	larepublica.es	<1%
7	Internet	sjimu.medilam.ac.ir	<1%
8	Internet	www.gsi.upm.es	<1%
9	Internet	www.revespcardiol.org	<1%
10	Internet	www.coursehero.com	<1%
11	Internet	1library.co	<1%

12	Internet	
eprajournals.com		<1%
13	Internet	
renati.sunedu.gob.pe		<1%
14	Publication	
Quintana Quispe, José Orlando. "Análisis predictivo de la deserción estudiantil en..."		<1%
15	Internet	
repositorio.unal.edu.co		<1%

Modelos de aprendizaje automático para mantenimiento predictivo: detección anticipada de fallas en tecnología médica usando Random Forest y XGBoost.

Abstract—Maintenance is a vital part of optimal management of medical equipment; predictive maintenance of medical devices in hospital environments is an increasing necessity where a failure of a device or medical equipment can not only decrease the patient's health but also their safety, thus affecting the continuity of service. In this study, we have focused on the use of artificial intelligence to anticipate or predict failures in medical equipment, using a dataset of historical records extracted from the internal management platform. The model analyzes failure reports generated between 2021-2025 in various hospital areas, in order to identify which equipment is at greater risk of recurring failures. Two supervised classification models were trained and compared: Random Forest and XGBoost, evaluating their performance using metrics such as accuracy, sensitivity, F1-score, and AUC. The results demonstrate that both models provide a high level of accuracy in prediction, with Random Forest being more sensitive to positive cases and XGBoost being more balanced in overall classification. These findings illustrate the potential of machine learning models as a strategic support in decision-making for clinical engineering, allowing for the prioritization of interventions and the optimization of hospital maintenance management.

Index Terms—Random Forest, XGBoost, IA, Biomedical engineering, Predictive Maintenance.

I. INTRODUCCIÓN

En entornos hospitalarios modernos, el adecuado funcionamiento del equipamiento médico es vital para garantizar la calidad en los servicios clínicos y la seguridad del paciente. Ante esta necesidad, en los últimos años los sistemas de gestión de mantenimiento a equipamiento médico han evolucionado hacia enfoques más reales basados en datos, permitiendo no solamente el seguimiento de fallas sino también anticiparse a las mismas lo que comúnmente en el ámbito de la ingeniería llamado mantenimiento predictivo, es un enfoque de anticipación a eventos críticos. Estamos en la donde la inteligencia artificial (IA) se ha consolidado como una herramienta para el desarrollo de modelos predictivos que ayuden a optimizar la toma de decisiones en diversas áreas de la biomedicina.

En este caso esta investigación tiene como objetivo aplicar técnicas de aprendizaje automático para predicción de fallas en equipamiento médico, partimos del análisis de históricos de reportes recopilados de la plataforma EMEKA. Esta plataforma creada con el fin de gestionar reportes de fallas de diversas

áreas hospitalarias, permite registrar y gestionar reportes de fallas relacionadas con equipamiento médico [1].

Se analizaron alrededor de 2000 registros correspondientes a los periodos 2021-2025, abarcando reportes generados por personal de enfermería y usuarios clínicos de unidades como cuidados intensivos, sala de operaciones, hospitalización, endoscopia, laboratorio clínico, maternidad, emergencia, cada entrada incluye información detallada sobre el equipo, falla reportada, clasificación de riesgo, ubicación del equipo, fecha y hora del reporte. A partir de este conjunto de datos, se desarrolló un modelo supervisado para identificar que equipos presentan mayor probabilidad de fallo a corto o mediano plazo.

Para ello, se implementaron y compararon dos algoritmos ampliamente utilizados en clasificación: **Random Forest** y **XGBoost**. Ambos fueron evaluados en términos de precisión, sensibilidad, F1-score y área bajo la curva ROC (AUC), con el propósito de determinar cuál ofrece mejor desempeño en un entorno hospitalario real y desbalanceado. La finalidad práctica de este estudio es proporcionar al departamento de ingeniería biomédica una herramienta predictiva que permita priorizar intervenciones preventivas y gestionar los recursos de mantenimiento de forma más eficiente.

II. MATERIALES Y MÉTODOS

A. Dataset

Los datos usados para este estudio lo que llamamos comúnmente dataset se extrajeron de una plataforma usada para la gestión de incidentes relacionados con el uso de equipos médicos, esta plataforma solicita al usuario que puede ser enfermera o auxiliar de enfermería que complete la siguiente información: Nombre del equipo, Marca, Modelo, breve explicación de la falla presentada por el equipo, área, fecha, nombre de persona que realiza el reporte. Una vez generado el reporte por el usuario, esta información es recibida por el personal del área de biomedicina el cual se encarga de brindar una solución al reporte.

El dataset cuenta alrededor de 1500 registros de reportes de fallas de diversas áreas hospitalarias unidad de cuidados intensivos, hospitalización, endoscopia, sala de operaciones, emergencia. Estos son los registros correspondientes de los años 2021 al 2025. Cabe mencionar que cada equipo en

listado en este registro esta clasificado según su riesgo Clase I, Clase II, Clase III.

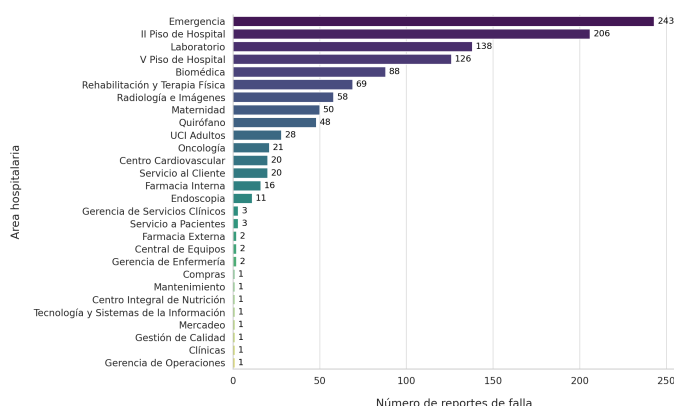


Fig. 1. Dataset de distribución de fallas.

En la Figura 1. se puede apreciar la distribución del dataset por área hospitalaria.

B. Preprocesamiento

Los datos recopilados de la plataforma de gestión de fallas en equipos médicos antes de ser analizados conllevan una etapa de pre-procesamiento.

- **Conversión de formato de fecha a datetime**
Consiste en transformar valores tipo texto o cadena a un formato que pueda ser interpretado o reconocido en este caso por python. En este caso específico se transformaron los datos para eliminar posibles errores durante el procesamiento.
- **Limpieza de datos**
Eliminación de registro duplicados que nos pueden arrojar resultados no válidos.
- **Etiquetas generalizadas**
consolidación de etiquetas similares que tienen el mismo significado, esto con el fin de establecer un estándar.
- **Codificación de variable**
Las variables emblemáticas en este caso Equipment y Área fueron transformadas en variables numéricas para ser procesadas de una mejor manera por el algoritmo.
- **Generación de variable objetivo**
Creación de una variable binaria llamada Falla Próxima que indica si un equipo ha presentado fallas más de 3 veces en su historial. Esta variable fue usada para el entrenamiento del modelo.

C. Modelos Aplicados

- **Random Forest**
Como lo comenta [2] este es un método de análisis de datos bastante versátil que nos permite realizar tareas como regresión lineal y clasificación de datos basados en múltiples árboles de decisión. Aplicado a este estudio se utilizó la librería scikit-learn creando un algoritmo basado en múltiples árboles de decisión cada uno entrenado sobre una muestra de datos aleatoria del dataset, no se

estimo conveniente el uso de hiperparámetros. Respecto a las variables de entrada esta incluyeron categorías codificadas por ejemplo la naturaleza del equipo médico y el área. La variable objetivo fue definida como binaria: se asignó un valor de 1 a los equipos con **tres o más fallas registradas** (indicando alta probabilidad de falla futura) y 0 en caso contrario.

• XGBoost (eXtreme Gradient Boosting)

Algoritmo de aprendizaje automático de tipo ensamblado que se utiliza comúnmente para problemas de clasificación y regresión. Se basa en la idea de construir un modelo complejo a partir de una secuencia de modelos más simples y se ha demostrado ser uno de los algoritmos más efectivos de la actualidad [3].

Enfocándonos en nuestro estudio actual se utilizó el clasificador XGBClassifier configurada por defecto, no se consideró necesaria la hiperparametrización ya que el objetivo del estudio es la comparación de ambos modelos. Al igual que el modelo anterior las variables de entrada esta incluyeron categorías codificadas por ejemplo la naturaleza del equipo médico y el área. La variable objetivo fue definida como binaria: se asignó un valor de 1 a los equipos con **tres o más fallas registradas** (indicando alta probabilidad de falla futura) y 0 en caso contrario.

D. Evaluación

Con el fin de evaluar los modelos predictivos desarrollados usamos las siguientes métricas de evaluación

- **Precisión (accuracy)**
La precisión en un método de prueba se logra cuando las determinaciones o análisis repetidos sobre la misma muestra arrojan resultados consistentes. En el contexto de la exactitud, un método de prueba preciso exhibe una variación aleatoria mínima, lo que aumenta la confianza en su fiabilidad. La capacidad del método de prueba para reproducir resultados consistentemente a lo largo del tiempo subraya su dependabilidad [4]. Esto nos indica el porcentaje total de predicciones correctas realizadas por el modelo.
- **Recall**
Proporción de verdaderos positivos entre el total de verdaderos casos (verdaderos positivos + falsos negativos). Mide la capacidad del modelo para detectar todas las muestras positivas [5]. Esta métrica clave cuando es prioritario no dejar pasar casos importantes, como una posible falla crítica de un equipo.
- **F1 score**
medida que combina la precisión y el recall para proporcionar una evaluación más completa del desempeño de un algoritmo de clasificación. Se calcula como la media armónica de la precisión y el recall [6].
- **AUC**
métrica utilizada para evaluar la capacidad de un modelo de clasificación para distinguir entre clases. En particular, se aplica a la curva ROC (Receiver Operating Characteristic), que representa la tasa de verdaderos positivos (TPR)

frente a la tasa de falsos positivos (FPR) a diferentes umbrales de decisión. La AUC mide el área bajo esta curva ROC y proporciona una medida única del rendimiento del modelo, donde un valor más alto de AUC indica un mejor rendimiento en la clasificación de los datos [7].

III. RESULTADOS

TABLE I
COMPARACIÓN DE DESEMPEÑO ENTRE LOS MODELOS RANDOM FOREST Y XGBOOST

Métrica	Random Forest	XGBoost
Accuracy	0.96	0.88
Precisión	0.97	0.97
Recall	1.00	0.90
F1-score	0.98	0.93
AUC	0.836	0.838

Los resultados obtenidos demuestran que ambos modelos, Random Forest y XGBoost, son altamente efectivos en la identificación de equipos con alta probabilidad de falla (Clase 1), definidos como aquellos que han presentado tres o más fallas en el periodo analizado.

El modelo Random Forest alcanzo una precision del 97%, , recall 100%y un F1-score de 0.98,con una exactitud del 96%.Estos valores indican que el modelo fue capaz de detectar la totalidad de los casos positivos sin generar falsos negativos,lo que es critico en aplicaciones donde no se debe omitir equipos en riesgo.

Por otra parte ,XGBoost mostro un desempeño bastante competitivo, con una precisión del **97%**, un recall del **90%** y un F1-score de **0.93**, alcanzando una exactitud global del **88%**. Aunque ligeramente inferior en recall, XGBoost mantuvo una buena capacidad predictiva, ofreciendo además una mayor estabilidad en la detección de ambas clases, como reflejó su valor de AUC ligeramente superior (**0.838** frente a **0.836** en Random Forest).

De manera conjunta ambos modelo ofrecen una base confiable para desarrollo de herramientas de mantenimiento predictivo, pero XGBoost cuenta con cierta ventaja en vista que es un modelo mas robusto que proporciona un equilibrio antes datos no lineales o des balanceados.




Fig. 2.




Fig. 3.

Podemos observar las figuras 2 y 3 presentan las matrices de confusión obtenidas para los modelos Random Forest y XGBoost, respectivamente. En ambas se evalúa la capacidad de clasificación entre dos clases:

- **Clase 1:** Equipos con fallas recurrentes (3 fallas)
- **Clase 0:** Equipos sin historial de fallas críticas




Fig. 4.

En la Figura.4 podemos visualizar el comportamiento de la predecir del modelo, aquí podemos visualizar los equipos que tienen mas altas probabilidad de presentar fallos.A simple vista el equipo con mayor probabilidad de falla son las bombas de infusión seguidamente de las camas hospitalarias,camillas de transporte y balanzas digitales.Estos equipos obtuvieron valores de probabilidad de falla superiores a 0.90, lo que indica un comportamiento histórico recurrente en reportes de fallas.

Esta visualización permite al personal del área de ingeniería clínica **identificar prioridades de mantenimiento predictivo**, y enfocar recursos en aquellos dispositivos con mayor riesgo operativo, contribuyendo a la continuidad de los servicios hospitalarios y la seguridad del paciente.

IV. DISCUIONES

Los resultados sugieren que el número de fallas acumuladas, junto con la ubicación y tipo de equipo, son predictores

confiables para anticipar fallas futuras. La aplicación práctica de estos modelos permitiría priorizar mantenimientos, redistribuir recursos técnicos y reducir tiempos de inactividad. Sin embargo, la perfección en las métricas sugiere que el modelo podría estar sobre ajustado o que el dataset necesita mayor variedad para evaluación más realista.

V. CONCLUSIONES

- Los modelos de aprendizaje automático Random Forest y XGBoost demostraron ser eficaces para predecir fallas en equipos médicos con base en datos históricos de una plataforma hospitalaria de gestión de mantenimiento. Ambos modelos alcanzaron altos niveles de precisión, con Random Forest mostrando una mayor sensibilidad a los casos positivos (equipos que efectivamente fallaron).
- La capacidad de anticipar qué equipos son más propensos a fallar permite a los departamentos de ingeniería biomédica implementar estrategias de mantenimiento predictivo más efectivas. Esto no solo optimiza los recursos técnicos, sino que contribuye a la seguridad del paciente y la continuidad de los servicios asistenciales.
- Aunque ambos modelos ofrecieron resultados robustos, Random Forest destacó por su sensibilidad del 100% en la detección de fallas recurrentes, lo cual lo hace especialmente útil en entornos donde es prioritario minimizar los falsos negativos.
- Esta metodología puede integrarse fácilmente en plataformas digitales como EMEKA u otros sistemas de gestión hospitalaria, permitiendo una automatización inteligente de alertas, priorización de equipos y planificación de intervenciones.
- El uso de inteligencia artificial en mantenimiento biomédico representa un paso clave hacia una gestión hospitalaria basada en datos, más eficiente y alineada con los principios de calidad y mejora continua en salud.

REFERENCES

- [1] E. Martzel, "EMEKA: Plataforma de gestión de mantenimiento biomédico," 2025. Sistema interno de gestión de fallas hospitalarias.
- [2] D. L. G. Ramírez, "Desarrollo de un aplicativo web para el apoyo de identificación de fallas comunes en máquinas de anestesia en un hospital de alta complejidad," 2022. Escuela Colombiana de Ingeniería Julio Garavito.
- [3] A. J. P. Celestino, K. R. G. Bravo, and J. L. R. Becerra, "Aplicación de modelos de aprendizaje supervisados para la prevención sobre fallos de maquinaria," *UCV Hacer*, vol. 12, no. 2, pp. 9–17, 2023.
- [4] M. A. D. Olivios, H. M. H. Del Águila, and F. M. S. López, "Diagnóstico de cáncer oral mediante algoritmos de aprendizaje profundo," *Ingenius. Revista de Ciencia y Tecnología*, vol. 32, pp. 58–68, 2024.
- [5] T. A. Losada Aristizábal, "Machine learning y seguridad: detección de amenazas e intrusión," 2024.
- [6] J. P. R. Villamizar, "Detección de ataques de tipo fuzzer en redes iot empleando algoritmos de clasificación de machine learning."
- [7] O. F. REA-CHAMORRO, *DISEÑO DE UN MODELO BASADO EN TÉCNICAS DE MACHINE LEARNING PARA LA CLASIFICACIÓN DE IMÁGENES MÉDICAS DEL CÁNCER PULMONAR: CONTRIBUCIÓN AL DIAGNÓSTICO MÉDICO*. PhD thesis, UNIB. E, 2024.