

CONESCAPANHONDURAS2025paper45.pdf

 Institute of Electrical and Electronics Engineers (IEEE)

Document Details

Submission ID

trn:oid:::14348:477750782

Submission Date

Jul 31, 2025, 11:48 PM CST

Download Date

Aug 12, 2025, 2:29 PM CST

File Name

CONESCAPANHONDURAS2025paper45.pdf

File Size

461.7 KB

6 Pages




4,708 Words

26,772 Characters

18% Overall Similarity

The combined total of all matches, including overlapping sources, for each database.

Top Sources

- 17%  Internet sources
- 14%  Publications
- 0%  Submitted works (Student Papers)

Integrity Flags




0 Integrity Flags for Review

No suspicious text manipulations found.

Our system's algorithms look deeply at a document for any inconsistencies that would set it apart from a normal submission. If we notice something strange, we flag it for you to review.

A Flag is not necessarily an indicator of a problem. However, we'd recommend you focus your attention there for further review.

Top Sources

- 17%  Internet sources
- 14%  Publications
- 0%  Submitted works (Student Papers)

Top Sources

The sources with the highest number of matches within the submission. Overlapping sources will not be displayed.

1	Internet	arxiv.org	2%
2	Internet	users.encs.concordia.ca	<1%
3	Internet	cbr.robocup.org.br	<1%
4	Internet	web.archive.org	<1%
5	Publication	Liwei Huang, Bitao Jiang, Shouye Lv, Yanbo Liu, Ying Fu. "Deep Learning-based Se...	<1%
6	Publication	Erzal Syahreza Aswir, Wasilah Wasilah. "Implementasi YOLOv3 Menggunakan Fit...	<1%
7	Publication	S Parvathavarthini, K S Sharvanthika, S Sindhu, K Kaviya. "Fetal Head Circumferen...	<1%
8	Internet	assets-eu.researchsquare.com	<1%
9	Internet	obgyn.onlinelibrary.wiley.com	<1%
10	Publication	D. A. Lyutkin, A. Y. Romanov, N. D. Nasonov. "Segmenting Prostate Cancer on TRU...	<1%
11	Internet	juti.if.its.ac.id	<1%

12	Internet	zagan.unizar.es	<1%
13	Internet	cora.ucc.ie	<1%
14	Internet	export.arxiv.org	<1%
15	Publication	Roger Bessis. "Réponse de R. Bessis et al. à l'éditorial de E. Verspyck et al.:«Quel r...	<1%
16	Publication	Zhihao Li, Liyan Chen, Li Lu, Ye Ding, Xiuxiu Hao. "Chapter 37 YOSAM: A YOLO and...	<1%
17	Internet	research.rug.nl	<1%
18	Internet	www.techscience.com	<1%
19	Internet	dinhtranngochuy.com	<1%
20	Internet	www.coursehero.com	<1%
21	Internet	www.uece.br	<1%
22	Internet	docta.ucm.es	<1%
23	Internet	pure.tue.nl	<1%
24	Publication	Jairo De Oliveira, Natalia Riveros, Arturo Gonzalez, Victorio Oxilia. "Energy Efficie...	<1%
25	Internet	www.mdpi.com	<1%

26	Internet	www.wikicfp.com	<1%
27	Internet	open.library.ubc.ca	<1%
28	Publication	Abraham Gamarra-Moreno, Luis Aroni-Ordoñez, Edson Ambrosio-Carrasco, Sergi...	<1%
29	Internet	hdl.handle.net	<1%
30	Internet	m.riunet.upv.es	<1%
31	Publication	Marco Paul E. Apolinario, Daniel A. Urcia Paredes, Samuel G. Huaman Bustamant...	<1%
32	Internet	cusam.edu.gt	<1%
33	Internet	repository.udistrital.edu.co	<1%
34	Publication	L.J. Salomon, Z. Alfircic, F. Da Silva Costa, R.L. Deter et al. "ISUOG Practice Guideli...	<1%
35	Internet	patents.google.com	<1%
36	Internet	wiki.appx.com	<1%
37	Internet	www.diee.unican.es	<1%
38	Internet	www.researchgate.net	<1%
39	Publication	Jhon Jairo Sáenz Gamboa. "Machine Learning en Resonancia Magnética. Describie...	<1%

Análisis comparativo de codificadores preentrenados en U-Net para la estimación de la circunferencia cefálica fetal en ecografías

1st Given Name Surname
dept. name of organization (of Aff.)
name of organization (of Aff.)
City, Country
email address or ORCID

2nd Given Name Surname
dept. name of organization (of Aff.)
name of organization (of Aff.)
City, Country
email address or ORCID

Resumen—La medición precisa de la circunferencia cefálica (HC) durante el embarazo es crucial para la detección temprana de anomalías y la toma de decisiones clínicas. Debido a la naturaleza ruidosa y variable de las imágenes ecográficas, automatizar esta medición representa un desafío importante. Las técnicas modernas de segmentación basadas en aprendizaje profundo ofrecen una solución prometedora para abordar esta tarea con mayor consistencia. En este estudio, se presentan y evalúan tres modelos de segmentación basados en redes neuronales convolucionales (CNN) con arquitectura U-Net, utilizando codificadores preentrenados (MobileNetV2, ResNet50 y EfficientNet-B3) para la medición automática de HC. Se empleó el conjunto de datos público HC18, compuesto por imágenes ecográficas, aplicando técnicas de aumento de datos y relleno de máscaras para mejorar el desempeño de la segmentación. La estimación de la HC se realizó ajustando una elipse al contorno predicho y aplicando la fórmula de Ramanujan. Los resultados muestran que el modelo basado en EfficientNet-B3 obtuvo el mejor desempeño, alcanzando un error porcentual medio del 1.12%, valor clínicamente aceptable. Estos resultados sugieren que el modelo propuesto tiene potencial como herramienta fiable de apoyo en la evaluación biométrica fetal.

Palabras clave— Biometría Fetal, Circunferencia Cefálica, Codificadores Preentrenados, Redes Neuronales Convolucionales, Segmentación, U-Net

I. INTRODUCCIÓN

La medición del perímetro cefálico en los exámenes rutinarios obstétricos es fundamental para la identificación de anomalías en el desarrollo fetal, diagnosticando enfermedades de manera precisa como macrocefalia, microcefalia, hidrocefalia, que son condiciones que se desarrollan desde el periodo gestacional y están directamente relacionadas con la medición de la cabeza [1]. La medición de la circunferencia cefálica también se relaciona con la edad gestacional, además de ser un indicador de parto por cesárea si la medida de la cabeza del feto es mayor en relación con la medida de la pelvis de la madre, en decir, la medición precisa conlleva la toma de decisiones médicas importantes.

Según la Sociedad Internacional de Ultrasonido en Obstetricia y Ginecología (ISUOG), que describe las buenas prácticas médicas para la evaluación adecuada de la biometría fetal, la medición de circunferencia cefálica (HC) desde el vientre,

se realiza mediante ecografías fetales, teniendo dos métodos posibles. El primero, y considerado el más preciso, consiste en que el ecografista ajuste manualmente una elipse que encierre la cabeza del feto, asegurándose de identificar el plano anatómico correcto para la medición [2]. El segundo método se basa en trazar líneas que representen los diámetros biparietal y occipitofrontal, y calcular posteriormente la HC aplicando una fórmula estandarizada incluida en la guía práctica de la ISUOG [3]. La experiencia del operador, el trazado de elipse y el plano de medición seleccionado por el ecografista influyen directamente en las mediciones, que en algunos casos pueden llegar a ser poco precisas. Ante esta situación, la automatización computacional de la medición de HC, desarrolla una alternativa innovadora, mejorando la eficiencia y consistencia de las evaluaciones obstétricas rutinarias.

Existen diversos estudios que proponen soluciones para la automatización de la medida de HC. La inteligencia artificial (IA) ha demostrado ser de valiosa utilidad para el campo de la medicina. La técnica más utilizada y la base de nuestro estudio es la segmentación semántica. Este proceso permite detectar de manera precisa la región de la cabeza, separándola de otros elementos de la ecografía, para posteriormente hacer una estimación del perímetro cefálico.

El crecimiento exponencial del uso de la IA y la disponibilidad de grandes volúmenes de datos han impulsado la investigación de diversas técnicas de visión por computador aplicadas a la biometría fetal. La segmentación basada en redes neuronales convolucionales (CNN, por sus siglas en inglés) está siendo ampliamente utilizada en el campo de la medicina por su capacidad de procesar imágenes 2D y 3D. Las CNN que se entrenan píxel a píxel superan los estándares de la última generación para la segmentación semántica [4].

Estudios recientes han consolidado el uso de redes neuronales convolucionales como enfoque estándar para abordar la problemática de la estimación automática de la circunferencia cefálica. En este contexto, el conjunto de datos HC18 ha representado un punto de partida clave en las investigaciones, al proporcionar una base sólida para el desarrollo y evaluación de técnicas basadas en CNN orientadas a mejorar la precisión

en la estimación del perímetro cefálico. Entre las propuestas recientes, destaca un modelo basado en la arquitectura One-to-Many U-Net, que alcanzó un coeficiente Dice de 96.54% y un IoU de 94.94% para la segmentación de la cabeza fetal [5]. Otras investigaciones han explorado diferentes arquitecturas y técnicas más complejas. Por ejemplo, El método DAG V-Net empleó una función de pérdida híbrida que obtuvo un Dice de 97.93% con 30 horas de entrenamiento y un error promedio de medición entre el calculado y el real de 1.77mm [6]. Asimismo, SAP-UNet, una variante de U-Net con arquitectura más profunda y mayor capacidad de representación, obtuvo un Dice del 98.02% [7]. No obstante, esta última presenta una alta demanda computacional, lo que puede limitar su aplicabilidad en entornos clínicos con recursos restringidos, donde se valoran modelos más livianos y eficientes.

En [8], se emplea la Transformada de Hough, un algoritmo de visión por computador que utiliza formas geométricas conocidas para ajustar o completar estructuras previamente segmentadas. Por otra parte, en [9] se propone un enfoque alternativo basado en una CNN de regresión para estimar directamente la circunferencia craneal, omitiendo el paso de segmentación. Aunque este método reduce la carga de trabajo manual, su precisión depende en gran medida de la calidad visual de las imágenes, lo que puede limitar su eficacia en condiciones clínicas reales.

Diversos modelos basados en U-Net son altamente eficaces para la segmentación biomédica en general, su arquitectura de codificación y decodificación permite manejar detalles espaciales relevantes para detección de objetivos en imágenes ecográficas [10].

Una línea prometedora para mejorar la precisión de la medición automatizada de HC sin incrementar la carga computacional es el uso de modelos preentrenados como ResNet50, EfficientNet o MobileNet. Estos modelos entrenados con grandes conjuntos de datos como ImageNet, ya han aprendido a reconocer patrones genéricos que pueden ser utilizados para detectar los bordes de una cabeza en una ecografía fetal. Esto permite construir modelos más especializados para identificar la región cefálica en imágenes ecográficas, lo cual es fundamental para que la medición de esa región sea precisa y confiable.

En este estudio proponemos validar la precisión biométrica en la estimación del HC a partir de imágenes ecográficas utilizando diferentes codificadores preentrenados basados en U-Net.

En la sección II se describe el conjunto de datos utilizado en esta investigación. La sección III detalla la metodología empleada, incluyendo el preprocesamiento de las imágenes y la arquitectura de los modelos implementados. En la sección IV se analizan los resultados obtenidos con el objetivo de determinar cuál modelo ofrece una mejor estimación de la circunferencia cefálica (HC), a través de un análisis cuantitativo basado en métricas estándar de segmentación y medición. Finalmente, en la sección V se presenta un resumen consolidado de los principales hallazgos y conclusiones del estudio.

II. CONJUNTO DE DATOS

El conjunto de datos que utilizamos fue publicado en 2018 como parte de una competencia internacional, denominado Fetal Head Circumference Challenge 2018 (HC18). Este dataset ha sido ampliamente utilizado para evaluar técnicas de segmentación del cráneo fetal.

HC18 está compuesto por 1,998 imágenes de entrenamiento: 999 imágenes de ultrasonido fetal en 2D, tomadas en plano axial, y sus correspondientes 999 máscaras de anotación elaboradas por un profesional que delinea el contorno de la cabeza fetal. El tamaño de píxel varía según el equipo utilizado para la toma de la ultrasonografía. Esta información se proporciona en el archivo “*training_set_pixel_size_and_HC.csv*” el cual contiene el nombre de cada imagen, el tamaño de píxel (escala) y la medida de HC en milímetros (mm) tomada por un ecografista capacitado de forma manual. Este archivo nos permite comparar nuestras medidas con los datos reales.

Además, el conjunto de datos incluye 335 imágenes de test; estas no incluyen imágenes con su respectiva anotación manual. El archivo “*test_set_pixel_size.csv*” proporciona la escala del píxel de cada imagen, información que se utiliza durante la evaluación del modelo en la fase de test.

III. METODOLOGÍA

En este estudio se emplea la arquitectura U-Net para la segmentación semántica de imágenes médicas. U-Net presenta una estructura simétrica en forma de “U”, compuesta por un codificador (encoder) que extrae representaciones jerárquicas y un decodificador (decoder) que genera el mapa de segmentación. Esta arquitectura es especialmente adecuada para tareas donde la precisión de los bordes es crítica, como en el caso de la biometría fetal.

Con el fin de evaluar el impacto de distintos extractores de características, se compararon tres variantes de codificadores preentrenados en ImageNet: ResNet50, MobileNetV2 y EfficientNet-B3, los cuales fueron integrados a la arquitectura U-Net. Cada uno de estos modelos fue adaptado como codificador dentro de la arquitectura U-Net estándar, manteniendo la simetría estructural del decodificador y las conexiones de salto (skip connections) características de la arquitectura original.




Fig. 1: Arquitectura basada en U-Net con codificador preentrenado

La Fig. 1 resume el flujo general del sistema propuesto, desde el preprocesamiento de las imágenes hasta la generación del mapa de segmentación. El codificador captura patrones de la imagen, como bordes o formas, reduciendo la imagen

a patrones jerárquicos por medio de capas convolucionales, convirtiéndola en un mapa de características y el decodificador es el que produce el mapa de segmentación [11].

ResNet50 [12] es un modelo que tiene capacidades de extracción de características profundas que se conectan con el decodificador mediante conexiones de salto. U-Net basado en ResNet ha demostrado superar al modelo original teniendo un buen equilibrio de resultados y eficiencia.

El modelo MobileNetV2 [13] fue inicialmente diseñado para móviles. Usa de bloques residuales invertidos con cuello de botella lineales, donde las capas convolucionales son de baja dimensionalidad.

EfficientNet-B3 [14] está basado en bloques MBConv (Mobile Inverted Bottleneck Convolution) y escalonado compuesto de profundidad, anchura y resolución, lo que lo hace ideal para tareas de visión por computadora.

A. Preprocesamiento de datos

Las imágenes ecográficas del conjunto de datos HC18 fueron redimensionadas a 800x540 píxeles (ancho x alto) con el fin de estandarizar la entrada a la red neuronal y asegurar una dimensión uniforme durante el entrenamiento.

Las máscaras proporcionadas originalmente en el dataset corresponden únicamente a los contornos de la cabeza fetal, lo que limita su utilidad directa en tareas de segmentación profunda. Para adaptarlas a un formato más adecuado para el aprendizaje profundo, se aplicó la biblioteca *OpenCV* para rellenar las áreas internas y obtener así máscaras binarias completas, como se ilustra en la Fig. 2b [15].

Sobre el conjunto de entrenamiento se aplicaron técnicas de aumento de datos utilizando la biblioteca *Albumentations*, incluyendo cambios de orientación de las imágenes, variaciones aleatorias de brillo y contraste, entre otros (Fig. 2a). Estas transformaciones permiten aumentar la variabilidad de los datos y mejorar la robustez del modelo ante diferencias clínicas en la adquisición de imágenes [16].




Fig. 2: a. Imagen ecográfica procesada con *Albumentations*. b. Máscara segmentada tras el relleno con *OpenCV*.

Para el conjunto de validación solo se aplicó el redimensionamiento, normalización y transformación a tensores para mantener la compatibilidad con los codificadores preentrenados en ImageNet.

Las imágenes ecográficas dentro de *training_set* en el dataset HC18 se dividieron en un 80% para entrenamiento y un 20% para validación. Esta división permite evaluar

el desempeño del modelo sobre datos no vistos durante el entrenamiento, proporcionando una estimación más realista de su capacidad de generalización y asegurando la integridad clínica del conjunto de validación.

B. Función de pérdida

En tareas de segmentación de imágenes médicas, es común enfrentar un marcado desequilibrio entre las clases, donde el fondo ocupa una gran parte de la imagen y el objeto de interés representa una proporción significativamente menor. Para abordar este problema y mejorar la sensibilidad del modelo ante regiones pequeñas o difíciles de segmentar, se empleó una función de pérdida compuesta.

La ecuación (1) describe dicha función de pérdida, la cual combina tres componentes: Binary Cross-Entropy (BCE), Dice Loss y Focal Loss.

$$TotalLoss = BCELoss + DiceLoss + FocalLoss \quad (1)$$

BCEWithLogitsLoss (Binary Cross Entropy con logits) evalúa cada píxel de forma independiente, minimizando el error promedio entre la máscara predicha y la real, al tratar cada píxel como una predicción binaria [17]. Sin embargo, esta función por sí sola puede verse afectada cuando existe un desequilibrio entre clases. Por ejemplo, en una ecografía del segundo trimestre de embarazo, suele haber una mayor proporción de fondo en comparación con una del tercer trimestre.

Para compensar esta limitación, se incorpora Dice Loss, una métrica basada en la superposición entre la segmentación predicha y la real. Esta función favorece la generación de máscaras más completas y coherentes, al tiempo que mejora la sensibilidad del modelo ante estructuras pequeñas que podrían ser ignoradas por BCE.

Focal Loss controlado por gamma se enfoca en ejemplos difíciles de segmentar, aumentando el peso de los píxeles dudosos para que el modelo aprenda de ellos. Esto refuerza el aprendizaje en regiones más desafiantes y ayuda a mejorar los detalles en bordes o en píxeles complicados [18].

C. Optimizador

Durante el entrenamiento, el optimizador se encarga de ajustar los parámetros del modelo para minimizar la función de pérdida, permitiendo una mejora progresiva a lo largo de las épocas. En este estudio se utilizó el optimizador *AdamW*, una variante de Adam que incorpora regularización L2 mediante el parámetro *weight_decay*. Esta modificación ha demostrado mejorar el desempeño en tareas de visión por computador al reducir el sobreajuste [19]. En nuestro caso, se utilizó una penalización de 1×10^{-5} .

Por otro lado, la tasa de aprendizaje (LR, por sus siglas en inglés) controla la magnitud de los ajustes aplicados a los pesos del modelo en cada iteración. Se empleó un valor inicial de 1×10^{-4} , el cual ha demostrado ser eficaz en tareas de segmentación con optimizadores como AdamW, al lograr una buena convergencia sin inducir sobreajuste.

D. Entrenamiento

Durante el entrenamiento, los tres modelos mantuvieron una arquitectura U-Net básica con una estructura de decodificación común, la misma función de pérdida compuesta (BCE + Dice + Focal) y el optimizador AdamW. Las condiciones de entrenamiento fueron consistentes entre todos los experimentos, diferenciándose únicamente en el codificador empleado: MobileNetV2, ResNet50 y EfficientNet-B3.

Estos codificadores fueron seleccionados por ser referencias representativas dentro de sus respectivas familias arquitectónicas en visión por computador. Los tres codificadores están enfocados en la segmentación semántica además de equilibrar eficiencia computacional y precisión, a diferencia de otros codificadores de mayor complejidad computacional.

Cada modelo fue entrenado durante 25 épocas utilizando el mismo conjunto de entrenamiento y validación, con un tamaño de lote (batch size) de 4 imágenes. Al utilizar un codificador preentrenado, gran parte del conocimiento visual general lo ha aprendido a diferenciar previamente, como consecuencia requiere menos épocas que si se entrenara desde cero. Además, la función de pérdida robusta que se ha implementado ayuda a alcanzar una convergencia y generalización dentro de este intervalo de entrenamiento sin caer en sobreajuste.

E. Medición de circunferencia cefálica

La salida del modelo es un mapa de probabilidad con valores entre 0 y 1, generado mediante una función sigmoide aplicada a los logits de la última capa. Para convertir esta salida en una máscara binaria, se aplicó un umbral de decisión: los píxeles con valor mayor o igual a 0.5 fueron clasificados como pertenecientes a la región de interés (cabeza fetal), mientras que el resto fueron asignados al fondo.

Una vez obtenida la máscara binaria, se aplicaron técnicas de procesamiento morfológico mediante la biblioteca *OpenCV*. Primero, se utilizó la función `cv2.findContours()` para extraer el contorno externo más significativo. Luego, sobre este conjunto de puntos, se ajustó una elipse utilizando `cv2.fitEllipse()`, la cual permite aproximar la forma real de la cabeza fetal, incluso si la segmentación presenta pequeñas irregularidades.




Fig. 3: Máscara binaria predicha (izquierda) y resultado final de medición de HC con elipse ajustada (derecha).

La Fig.3 ilustra el proceso de medición de la circunferencia cefálica a partir de la segmentación predicha: a la izquierda se observa la máscara binaria generada por el modelo, y a la

derecha, la superposición del contorno detectado y la elipse ajustada sobre la imagen original.

Una vez ajustada la elipse, procedemos a un tratamiento común de la figura geométrica. Usando los semiejes mayor y menor, se calcula la circunferencia elíptica utilizando la fórmula de Ramanujan (2), que ofrece una alta exactitud para elipses con cualquier grado de excentricidad. Donde "a" es el semieje mayor y "b" es semieje menor.

$$HC_{px} \approx \pi[3(a+b) - \sqrt{(3a+b)(a+3b)}] \quad (2)$$

Finalmente, para obtener una medición en milímetros (mm) aplicamos la escala de píxel correspondiente a la imagen, disponible en el archivo "training_set_pixel_size_and_HC.csv", ocupando (3).

$$HC_{mm} = HC_{px} \times \text{pixel size (mm)} \quad (3)$$

F. Métricas de evaluación

El conjunto de datos HC18 incluye un conjunto de prueba (*test set*) que carece de máscaras segmentadas por expertos y valores reales de circunferencia cefálica, lo que imposibilita la evaluación directa del rendimiento en dicho conjunto. Por esta razón, las métricas reportadas se calcularon exclusivamente sobre el conjunto de validación, el cual no fue utilizado durante el entrenamiento y dispone de las anotaciones clínicas necesarias para una evaluación cuantitativa rigurosa.

Para evaluar el desempeño de los modelos entrenados, se emplearon métricas cuantitativas agrupadas en dos categorías principales: métricas de segmentación y métricas de medición. Esta distinción permite analizar por separado la calidad de la segmentación y la precisión en la estimación biométrica de la circunferencia cefálica, ya que una buena segmentación no siempre garantiza una medición exacta en contextos clínicos.

Las métricas de segmentación se enfocan en comparar la máscara generada por el modelo con la máscara de referencia hecha por un profesional médico: **Dice Coefficient** evalúa el grado de superposición o coincidencia de segmentación entre la predicción y la máscara real. Por su parte, **IoU** (Intersection over Union) mide cuán precisa y ajustada es la segmentación.

Adicionalmente, se emplean métricas tradicionales de clasificación: **Accuracy** (exactitud), devuelve el porcentaje de píxeles correctamente clasificados sobre el total de predicciones realizadas. **Precision** (precisión), se enfoca en el porcentaje de los píxeles predichos como positivos frente a los que realmente lo son, indicando qué tan confiables son las predicciones positivas del modelo y **recall** (sensibilidad), que mide la capacidad del modelo para encontrar todos los píxeles positivos reales, evaluando cuántos de ellos fueron correctamente identificados.

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$\text{IoU} = \frac{TP}{TP + FP + FN}$$

$$\text{Dice} = \frac{2TP}{2TP + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Donde:

- TP: True Positives (Verdaderos Positivos)
- FP: False Positives (Falsos Positivos)
- TN: True Negatives (Verdaderos Negativos)
- FN: False Negatives (Falsos Negativos)

Las métricas de medición de circunferencia cefálica (perímetro de la elipse ajustada) están relacionadas con las mediciones predichas y las reales, efectuadas por un profesional.

El **Error Absoluto Medio (MAE)** calcula la media de los errores absolutos entre la medición predicha y la real, en milímetros. El **Porcentual Absoluto Medio (MAPE)** expresa ese error en porcentaje. Ambas métricas se promedian sobre el conjunto de validación.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |HC_i^{(\text{pred})} - HC_i^{(\text{real})}|$$

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{HC_i^{(\text{pred})} - HC_i^{(\text{real})}}{HC_i^{(\text{real})}} \right|$$

Donde:

- n : número de imágenes en validación.
- HC : medición de circunferencia cefálica.

IV. ANÁLISIS DE RESULTADOS

Para este estudio se entrenaron tres modelos de segmentación con arquitectura U-Net y codificadores preentrenados diferentes: MobileNetV2, ResNet50 y EfficientNet-B3. Todos los modelos compartieron el mismo conjunto de datos (HC18), función de pérdida compuesta y condiciones de entrenamiento, permitiendo una comparación equilibrada.

La Tabla I muestra los resultados obtenidos para cada modelo evaluados en un mismo conjunto de validación y separados en dos grupos: las métricas de la segmentación de la cabeza fetal y la medición biométrica de la misma.

La Fig. 4 presenta una visualización comparativa del rendimiento alcanzado por cada modelo en las métricas de segmentación: IoU, Dice, Precisión, Recall y Exactitud. Los tres modelos alcanzaron un desempeño sobresaliente por encima del 93% y Dice superior al 96.70%. Sin embargo, el

Tabla I: Resultados de segmentación y medición de cabeza fetal en HC18

Métricas de segmentación	Codificadores preentrenados		
	MobileNetV2	ResNet50	EfficientNet-b3
IoU	94.49%	93.97%	95.93%
Dice	97.07%	96.76%	97.91%
Precision	97.58%	96.14%	98.19%
Recall	96.76%	97.61%	97.67%
Accuracy	98.55%	98.42%	98.86%
Métricas de medición			
MAE	2.13 mm	2.76 mm	1.78 mm
MAPE	1.49%	1.80%	1.12%

modelo que destacó más fue el entrenado con EfficientNet-b3, superando a los otros modelos en todas las métricas evaluadas, logrando un IoU de 95.93% y Dice 97.91%, lo que refleja una alta concordancia entre la segmentación predicha y la forma anatómica real de la cabeza fetal. Además, sus valores de precisión (98.19%) y sensibilidad (97.67%), sugieren que el modelo identifica con eficacia las regiones relevantes, minimizando omisiones que podrían afectar la medición precisa de la circunferencia cefálica.

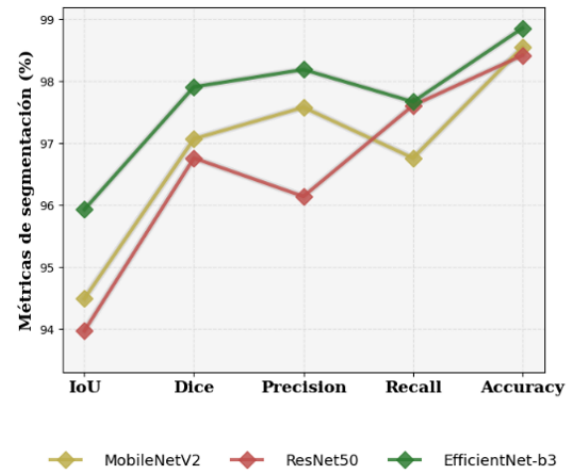


Fig. 4: Comparación de modelos: Métricas de segmentación

En cuanto a la medición biométrica de la circunferencia cefálica, el modelo basado en EfficientNet-B3 también logró los mejores resultados, con un MAE de 1.78 mm y un MAPE de 1.12 %. Estos valores reflejan una excelente precisión en la estimación del perímetro cefálico, manteniéndose dentro de márgenes clínicamente aceptables y demostrando su potencial como herramienta de apoyo en el entorno diagnóstico.

La Fig. 5 muestra un gráfico de dispersión que relaciona los valores reales y predichos de la circunferencia cefálica (HC) en el conjunto de validación utilizando el modelo EfficientNet-B3. Los puntos están situados muy próximos a la línea punteada, indicando una excelente correlación entre las mediciones predichas y las reales tomadas por un profesional. Esta visualización respalda cuantitativamente las métricas MAE y MAPE previamente presentadas.

Los resultados reflejan que el codificador EfficientNet-B3 captura mejor las características anatómicas presentes en

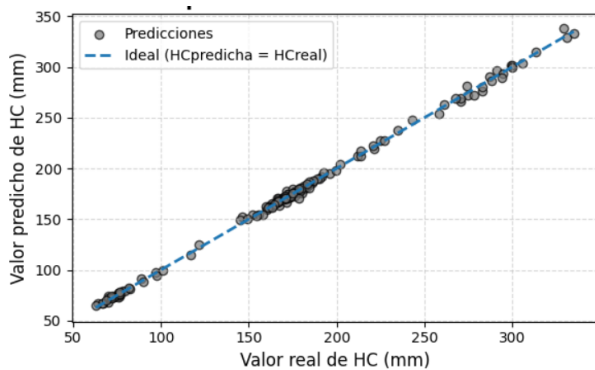


Fig. 5: Dispersión de valores reales vs. predichos de HC en el conjunto de validación con EfficientNet-B3.

ecografías fetales, demostrando una ventaja significativa en la calidad de segmentación y precisión de medición del HC. Estos resultados cobran más relevancia ya que superan la precisión técnica que ofrecen los diversos máquina-sonda en la práctica obstétrica [20].

V. CONCLUSIONES

En este estudio se desarrollaron y evaluaron tres modelos de segmentación basados en la arquitectura U-Net, integrando codificadores preentrenados: MobileNetV2, ResNet50 y EfficientNet-B3. Todos los modelos fueron entrenados bajo condiciones homogéneas, con el objetivo de segmentar la cabeza fetal y estimar de forma automática la circunferencia cefálica (HC) en imágenes ecográficas 2D, una métrica clave en la evaluación obstétrica.

El uso de codificadores preentrenados demostró ser altamente beneficioso, permitiendo a los modelos extraer características relevantes con mayor eficiencia, gracias al conocimiento previamente adquirido en tareas generales de visión por computador.

Además, la incorporación de un posprocesamiento geométrico robusto, mediante ajuste elíptico con OpenCV, permitió convertir las segmentaciones en mediciones cuantificables con alta precisión, incluso ante pequeñas imperfecciones en los bordes segmentados.

Aunque los tres modelos lograron un rendimiento destacado en las métricas de segmentación y medición, el modelo basado en EfficientNet-B3 superó sistemáticamente a los demás, demostrando mayor concordancia con las anotaciones clínicas y menor margen de error en la medición del perímetro cefálico.

En conjunto, estos resultados validan la eficacia de combinar arquitecturas U-Net con codificadores preentrenados y técnicas geométricas de posprocesamiento para tareas biométricas en imágenes médicas. Este enfoque tiene el potencial de integrarse en evaluaciones obstétricas rutinarias, facilitando diagnósticos más ágiles y precisos, y apoyando la toma de decisiones médicas en contextos clínicos reales.

REFERENCIAS

[1] V. G. Poojari, A. Jose, and M. V. Pai, "Sonographic estimation of the fetal head circumference: Accuracy and factors affecting the error,"

Journal of Obstetrics and Gynaecology of India, vol. 72, no. Suppl 1, pp. 134–138, 2022, epub 2021 Oct 9.

[2] L. Salomon, Z. Alfrevic, F. Da Silva Costa, R. Deter, F. Figueras, T. Ghi, and Glanc, "Isuog practice guidelines: ultrasound assessment of fetal biometry and growth," *Ultrasound in Obstetrics & Gynecology*, vol. 53, no. 6, pp. 715–723, 2019.

[3] L. J. Salomon, Z. Alfrevic, V. Berghella, C. M. Bilardo, G. E. Chalouhi, F. D. S. Costa, E. Hernandez-Andrade, G. Malinge, H. Munoz, D. Paladini, F. Prefumo, A. Sotiriadis, A. Toi, W. Lee, and I. C. S. Committee, "ISUOG Practice Guidelines (updated): Performance of the routine mid-trimester fetal ultrasound scan," *Ultrasound in Obstetrics & Gynecology*, vol. 59, no. 6, pp. 840–856, Jun. 2022, publicado en línea el 23mayo2022 mediante ISUOG, volumen 59(6) junio 2022.

[4] H. Jia, J. Zhang, K. Ma, X. Qiao, L. Ren, and X. Shi, "Application of convolutional neural networks in medical images: a bibliometric analysis," *Quantitative Imaging in Medicine and Surgery*, vol. 14, no. 5, pp. 3501–3518, May 2024, epub 2024 Apr 11.

[5] V. A. Chenarlogh, A. Hassanpour, K. Grolinger, and V. Parsa, "Performance analysis of dilated one-to-many u-net model for medical image segmentation," *IEEE Access*, vol. 12, pp. 197 259–197 274, 2024.

[6] Y. Zeng, P.-H. Tsui, W. Wu, Z. Zhou, and S. Wu, "Fetal ultrasound image segmentation for automatic head circumference biometry using deeply supervised attention-gated v-net," *Journal of Digital Imaging*, vol. 34, no. 1, pp. 134–148, Feb. 2021, epub 2021 Jan 22.

[7] A. A. Hekal, H. M. Amer, H. E.-D. Moustafa, and A. Elnakib, "Automatic measurement of head circumference in fetal ultrasound images using a squeeze atrous pooling unet," *Biomedical Signal Processing and Control*, vol. 103, p. 107434, 2025.

[8] T. L. A. van den Heuvel, D. de Bruijn, C. L. de Korte, and B. v. Ginneken, "Automated measurement of fetal head circumference using 2d ultrasound images," *PLOS ONE*, vol. 13, no. 8, pp. 1–20, 08 2018. [Online]. Available: <https://doi.org/10.1371/journal.pone.0200412>

[9] J. Zhang, C. Petitjean, P. Lopez, and S. Ainouz, "Direct estimation of fetal head circumference from ultrasound images based on regression cnn," in *Proceedings of the Third Conference on Medical Imaging with Deep Learning*, ser. Proceedings of Machine Learning Research, vol. 121. PMLR, 06–08 Jul 2020, pp. 914–922.

[10] L. Khaertdinova, T. Shmykova, I. Pershin, A. Laryukov, A. Khanov, D. Zidikhanov, and B. Ibragimov, "Gaze assistance for efficient segmentation correction of medical images," *IEEE Access*, vol. 13, pp. 14 199–14 213, 2025.

[11] N. Siddique, P. Sidike, and Elkin, "U-net and its variants for medical image segmentation: theory and applications," 11 2020.

[12] B. Xie, "A comparative study of medical image segmentation via resnet-driven unet architecture," in *2025 2nd International Conference on Digital Image Processing and Computer Applications (DIPCA)*, 2025, pp. 96–101.

[13] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "Mobilenetv2: Inverted residuals and linear bottlenecks," 2019.

[14] M. T. Ramakrishna, K. Pothanaicker, P. Selvaraj, S. B. Khan, V. K. Venkatesan, S. Alzahrani, and M. Alojail, "Leveraging efficientnetb3 in a deep learning framework for high-accuracy mri tumor classification," *Computers, Materials and Continua*, vol. 81, no. 1, pp. 867–883, 2024.

[15] S. Minaee, Y. Boykov, F. Porikli, A. Plaza, N. Kehtarnavaz, and D. Terzopoulos, "Image segmentation using deep learning: A survey," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 7, pp. 3523–3542, 2022.

[16] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, A. Parinov, M. Druzhinin, and A. A. Kalinin, "Albumentations: Fast and flexible image augmentations," *Information*, vol. 11, no. 2, 2020.

[17] U. Ruby and V. Yendapalli, "Binary cross entropy with deep learning technique for image classification," *International Journal of Advanced Trends in Computer Science and Engineering*, vol. 9, 10 2020.

[18] S. Wazir and M. M. Fraz, "Histoseg: Quick attention with multi-loss function for multi-structure segmentation in digital histology images," in *2022 12th International Conference on Pattern Recognition Systems (ICPRS)*. IEEE, Jun. 2022, p. 1–7.

[19] P. Zhou, X. Xie, Z. Lin, and S. Yan, "Towards understanding convergence and generalization of adamw," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 46, no. 9, pp. 6486–6493, 2024.

[20] R. Axell, C. Lynch, T. Chudleigh, L. Bradshaw, J. Mangat, P. White, and C. Lees, "Clinical implications of machine-probe combinations on obstetric ultrasound measurements used in pregnancy dating," *Ultrasound in Obstetrics & Gynecology*, vol. 40, no. 2, pp. 194–199, 2012.