

CONESCAPANHONDURAS2025paper55.pdf

 Institute of Electrical and Electronics Engineers (IEEE)

Document Details

Submission ID

trn:oid:::14348:477773251

Submission Date

Jul 31, 2025, 11:28 PM CST

Download Date

Aug 12, 2025, 2:37 PM CST

File Name

CONESCAPANHONDURAS2025paper55.pdf

File Size

719.3 KB

7 Pages




5,259 Words

27,256 Characters

31% Overall Similarity

The combined total of all matches, including overlapping sources, for each database.

Top Sources

- 29%  Internet sources
- 23%  Publications
- 0%  Submitted works (Student Papers)

Integrity Flags

1 Integrity Flag for Review



Hidden Text




6 suspect characters on 1 page

Text is altered to blend into the white background of the document.

Our system's algorithms look deeply at a document for any inconsistencies that would set it apart from a normal submission. If we notice something strange, we flag it for you to review.

A Flag is not necessarily an indicator of a problem. However, we'd recommend you focus your attention there for further review.

Top Sources

- 29%  Internet sources
- 23%  Publications
- 0%  Submitted works (Student Papers)

Top Sources

The sources with the highest number of matches within the submission. Overlapping sources will not be displayed.

1	Internet	
hdl.handle.net		3%
2	Internet	
ingenius.ups.edu.ec		2%
3	Internet	
repozitorij.fer.unizg.hr		1%
4	Publication	
Lafleti, Sipho Pelican. "Intelligent Fault Detection Technique for Distribution Net...		<1%
5	Internet	
dspace.ups.edu.ec		<1%
6	Internet	
www.ieee-jas.net		<1%
7	Internet	
ceur-ws.org		<1%
8	Internet	
rinfi.fi.mdp.edu.ar		<1%
9	Publication	
Shahabodin Afrasiabi, Mousa Afrasiabi, Behzad Behdani, Mohammad Mohamma...		<1%
10	Internet	
ijeecs.iaescore.com		<1%
11	Publication	
V. H. Gonzalez-Sanchez, V. Torres-Garcia, D. Guillen, Salvador Ramirez-Zavala. "Re...		<1%

12	Publication	Md Abu Saaklayen, Xiaodong Liang, Sherif O. Faried, Luigi Martirano, Peter E. Sut...	<1%
13	Internet	khazna.ku.ac.ae	<1%
14	Internet	archive.org	<1%
15	Internet	file.techscience.com	<1%
16	Publication	Faisal Mumtaz, Kashif Imran, Habibur Rehman, Hammad Ali Qureshi. "Hardware ...	<1%
17	Internet	revistas.ups.edu.ec	<1%
18	Internet	repository.unad.edu.co	<1%
19	Internet	ijece.iaescore.com	<1%
20	Internet	repositorio.unal.edu.co	<1%
21	Internet	repository.javeriana.edu.co	<1%
22	Publication	Rahman Dashti, Mohammad Daisy, Hamid Mirshekali, Hamid Reza Shaker, Mahm...	<1%
23	Publication	Sufiyan Rao, Syed Ali Abbas Kazmi, Muhammad Zubair Iftikhar, Thamer A.H. Algh...	<1%
24	Internet	www.coursehero.com	<1%
25	Publication	Isaac Ortega-Romero, Xavier Serrano-Guerrero, Antonio Barragán-Escandón, Chis...	<1%

26	Internet	ece.princeton.edu	<1%
27	Publication	Tran The Hoang, Quoc Tuan Tran, Yvon Besanger, Tung Lam Nguyen. "A New Dire...	<1%
28	Internet	www.researchgate.net	<1%
29	Publication	Zahra Mojaradi, Reza Tavakkoli-Moghaddam, Ali Bozorgi-Amiri, Jafar Heydari. "A t...	<1%
30	Internet	export.arxiv.org	<1%
31	Publication	Truyenque, Agustín Haggi Molina. "Caso de Estudio: Mecanismos de Supervisión ...	<1%
32	Internet	bdm.unb.br	<1%
33	Internet	iptek.its.ac.id	<1%
34	Internet	tel.archives-ouvertes.fr	<1%
35	Publication	"Aplicaciones e innovación de la ingeniería em ciencia y tecnología", FapUNIFESP ...	<1%
36	Publication	Ivan Dumancic, Carolina Tranchita, Joscha Kluge. "Dynamic Simulation of Distribu...	<1%
37	Internet	escholarship.org	<1%
38	Publication	Pachón Rodríguez, Willian Antonio. "Detección de Fraudes en Empresas de Servi...	<1%
39	Publication	Perez, Esteban Jove. "Advanced Anomaly Detection Algorithms Based on Virtual S...	<1%

40	Publication	Shivam Kushwaha, Ranjeet Singh, Ranjana Yadav, Vinod Kumar Yadav, Tanmay Y...	<1%
41	Internet	ruc.udc.es	<1%
42	Internet	addi.ehu.es	<1%
43	Internet	researchportal.northumbria.ac.uk	<1%
44	Publication	Janneth Rocio Secue. "<![CDATA[Review of Sweep Frequency Response Analysis -S...	<1%
45	Internet	issuu.com	<1%
46	Internet	journal.esrgroups.org	<1%
47	Internet	www.remorecover.com	<1%
48	Publication	MA Pérez-Chavarría, HH Hidalgo-Silva, FJ Ocampo-Torres. "Time series prediction ...	<1%
49	Internet	es.caimore.net	<1%
50	Internet	repositorio.unf.edu.pe	<1%
51	Internet	wikileaks.org	<1%
52	Internet	www.matec-conferences.org	<1%
53	Internet	bibdigital.epn.edu.ec	<1%

54	Internet	digital-library.theiet.org	<1%
55	Internet	doku.pub	<1%
56	Internet	geox.udistrital.edu.co	<1%
57	Internet	jurnal.ugm.ac.id	<1%
58	Internet	koreascience.kr	<1%
59	Internet	manglar.uninorte.edu.co	<1%
60	Internet	oa.upm.es	<1%
61	Publication	"Proceedings of the 4th Biotechnology World Symposium", Mexican Journal of Bi...	<1%
62	Publication	S.S. Gururajapathy, H. Mokhlis, H.A. Illias. "Fault location and detection technique...	<1%

Fault classification and location in distribution networks using MLP neural networks

Abstract— Given the unpredictability of faults in power distribution systems, it is crucial to have effective methods to locate and isolate them in order to minimize their impact. Consequently, over time, several methods have been developed to identify and detect faults in distribution networks. This paper presents an approach based on joint learning to identify fault types and their locations with only voltage and current measurements on distribution feeders (MV). Fault simulations were performed throughout the network to acquire voltage and current values at the substation. The results are recorded in a database and used to train a multilayer perceptron neural network capable of determining, with an average accuracy greater than 90%, the fault location among the possible zones determined according to the protection and switching equipment that delimits the mentioned zones. The evaluation of the model is carried out using data related to different fault types, their locations and various operational conditions on the IEEE 37-bus network separating the circuit into zones. The proposed approach can determine the fault type and its location using MLP neural networks without including measurement with emerging smart measurement equipment in the network.

Index Terms— Radial distribution networks, fault location, supervised learning, mlp.

I. INTRODUCCIÓN

LA creciente dependencia de la energía eléctrica en la vida cotidiana demanda una atención especial en la generación, transmisión y distribución de este recurso. A pesar de los avances en la protección de los sistemas eléctricos, la continuidad en el suministro de energía aún presenta desafíos significativos.

Los sistemas de distribución eléctrica están expuestos constantemente a posibles fallas, causadas por el deterioro de componentes debido al envejecimiento, incorrecta operación de la red y condiciones climáticas. En general, más del 75% de los cortes en el suministro eléctrico se deben a fallas en el sistema de distribución, lo que ha motivado a las compañías distribuidoras a implementar nuevas técnicas para la detección y localización eficientes de fallas [1]. Esto no solo previene daños en los equipos de la red, sino que también evita multas por la falta de suministro de energía a los clientes afectados [2].

Gran parte de la investigación del estado del arte en el campo de la localización de fallas se ha enfocado en las redes de transmisión, dejando en general a las redes de distribución en un segundo plano debido a su topología radial y la falta de equipos automatizados y poca observabilidad de la red [3].

La aplicación de técnicas de localización de fallas es crucial para garantizar la calidad y confiabilidad del servicio, reduciendo los tiempos de interrupción. La calidad del servicio eléctrico puede mostrar su eficiencia, con sus indicadores principales: SAIDI que muestra la duración media de interrupciones por cliente por año y SAIFI que muestra la frecuencia media de

interrupciones por cliente por año [4]. Estos indicadores varían de acuerdo al tipo de empresa distribuidora (pública o privada) o incluso la zona geográfica que abarca, y de acuerdo con la regulación de cada país [5].

Es de notar que existen países con valores muy elevados de SAIDI y SAIFI y con el aumento de fallas en la red de distribución, surge la necesidad de implementar métodos para la pronta localización de fallas y considerar la infraestructura eléctrica de la red. Por lo cual este trabajo está orientado para proporcionar una herramienta que pueda localizar fallas en redes de distribución y así disminuir el indicador SAIDI.

Las fallas pueden causar interrupciones permanentes de energía si no se realizan mantenimientos adecuados [6], lo que hace crucial identificar sus causas y desarrollar técnicas de detección y restauración eficientes. Las operaciones no planificadas de los dispositivos de protección pueden interrumpir el servicio para los clientes aguas abajo, principalmente debido a sobrecargas, errores de coordinación o fallas en la red [7]. Los datos estadísticos muestran que las fallas en la red de distribución son mayormente temporales, entre el 75-90% pero las permanentes, especialmente las de baja impedancia, pueden causar interrupciones mayores a 1 hora [8] por lo que identificar y clasificar estas fallas es esencial para su manejo eficiente. En cambio, las fallas de alta impedancia son menos frecuentes que las fallas de baja impedancia, estas no causan la activación de dispositivos de protección de sobrecorriente [9].

Las fallas en las redes de distribución se clasifican en monofásicas a tierra (LG), bifásicas aisladas (LL), bifásicas a tierra (LLG) y trifásicas (LLL y LLLG), representando respectivamente el 70%, 15%, 10% y 5% de las fallas. Las monofásicas son las más comunes, mientras que las trifásicas, a pesar de su baja frecuencia, son las más graves debido a su impacto total en la línea [8].

En este trabajo nos centraremos en las fallas permanentes de baja impedancia, que causan modificaciones no programadas en la configuración operativa hasta la reparación del equipo dañado. Los equipos modernos, como reconectadores y medidores inteligentes, proporcionan datos esenciales para el monitoreo en tiempo real y la identificación precisa de la ubicación de las fallas [10].

II. LOCALIZACIÓN DE FALLAS

En un sistema convencional de gestión de cortes o interrupciones del suministro eléctrico, cuando se produce una falla y el sistema de protección entra en acción, se realiza un proceso de mapeo de las interrupciones con el fin de localizar la causa del problema. Después, se restaura el suministro eléctrico a los usuarios afectados y se vuelve a poner en marcha la red hasta

que vuelva a la normalidad [11], como lo muestra en la Fig. 1.

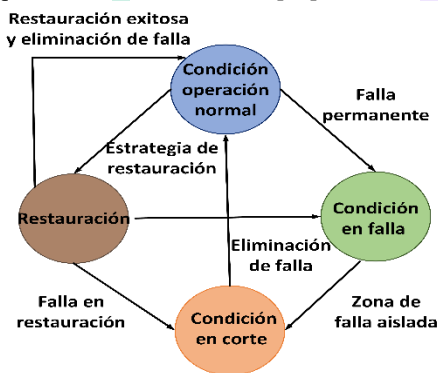


Fig. 1. Estados de detección, localización, restauración de falla.

Cuando una falla ocurre, el proceso de detección de corte tradicionalmente implica la agrupación de llamadas de clientes para determinar qué dispositivos de protección se activaron durante la falla [12].

El tiempo de detección y localización de fallas puede variar de acuerdo con las características de las redes de distribución, si se tienen dispositivos detectores de falla o no, y herramientas para su pronta localización [13]. Por lo que el objetivo principal del trabajo realizado es disminuir el tiempo de localización de fallas y así disminuir el SAIDI de las empresas distribuidoras.

Sin embargo, las mejoras en las mediciones y la infraestructura de teleoperación en las redes de distribución actuales permiten una gestión de fallas más rápida y efectiva. Esto reduce el tiempo de interrupción del suministro eléctrico y aumenta la satisfacción del usuario. [14].

A. Método basado en impedancia

Este método requiere mediciones de tensiones y corrientes de las subestaciones, así como datos de líneas y de las cargas siendo un algoritmo práctico tanto para redes tradicionales como modernas, aunque tiene la desventaja de realizar una estimación de múltiples localizaciones ya que consiste en determinar la impedancia de la localización de la falla a través del punto de medición como en la cabecera del alimentador.

En [15] utiliza el método de impedancia en conjunto de técnica de aprendizaje automático como lo es la red neuronal profunda y realiza el análisis con un terminal de línea con su dispositivo electrónico inteligente (IED) y con dos terminales de línea con sus respectivos IED.

En [16] el autor presenta un método mejorado basado en la impedancia con presencia de recursos de generación distribuida de energía fotovoltaica con mediciones de voltaje y corriente en el alimentador.

En [17] se propone un método de falla por impedancia combinado con un sistema multi-agente para localizar la falla de línea a tierra y luego restaurar el Sistema.

En [18] se presenta una formulación integrada que combina el enfoque de impedancia y el análisis de transitorios para la detección de fallas. Para una identificación más precisa de la falla, se propone un análisis de transitorios que evalúa el contenido espectral de la onda viajera generada por la falla.

B. Método basado en ondas viajeras

El método de localización de fallas por ondas viajeras se fundamenta en la medición de las señales eléctricas que se propagan a lo largo de la línea después de la ocurrencia de una falla. Dichas señales pueden ser analizadas para calcular con precisión la ubicación de la falla en la línea a partir de la transmisión y reflexión de las ondas viajeras entre la terminal de la línea y el punto de falla. Este método requiere dispositivos de adquisición de datos de alta velocidad, sensores e incluso GPS [8] para capturar la forma de onda para localizar la falla.

En [19] se presenta un método para localizar fallas de puesta a tierra monofásica, basado en las características de tiempo-frecuencia de la onda viajera. Se calcula la distancia de la falla utilizando la ecuación de localización que se basa en la diferencia de velocidad de onda de módulo.

En [20] se introduce un algoritmo de localización de fallas basado en ondas viajeras de fase única y con fase fallida para redes en bucle. Este algoritmo permite al sensor recibir múltiples señales reflejadas desde el punto de falla.

En [21] se propone un mecanismo para detección de fallas estableciendo una matriz de diferencia de distancia intrínseca (IDDM) basado en las propias características de propagación de ondas y topología de la red antes de que ocurra una falla y de esta manera, la onda viajera se descompone en varias funciones de modo intrínseco (IMF).

C. Método basado en aprendizaje

Todos los métodos antes mencionados pueden ser clasificado como métodos tradicionales o basados en un cálculo matemático posfalla [22] mientras que los métodos basados en aprendizajes se basan en técnicas que utilizan algoritmos de aprendizaje automático para predecir la ubicación de una falla en base a datos de entrada provenientes de sensores y otras fuentes. Son métodos cada vez más populares por su capacidad de proporcionar resultados precisos y confiables incluso en tiempo real.

En [23] se presenta una innovadora estrategia basada en el aprendizaje. El enfoque adoptado es un método de apilamiento (stacking) que se compone de dos niveles primarios, cada uno de los cuales incorpora uno o varios clasificadores independientes.

En [24] se introduce un método híbrido para localización de fallas de manera rápida con el uso de mediciones de voltajes y corrientes en la subestación principal y en los puntos de GD. Los datos son aprovechados por una red neuronal artificial (ANN, por sus siglas en inglés) de alimentación directa para poder estimar las distancias de falla.

En [25] se presenta una innovadora aproximación que emplea tanto una Red Neuronal Artificial (RNA) como una SVM. Los datos se analizan empleando la técnica de Análisis de Componentes Principales (PCA, por sus siglas en inglés), y las fallas se categorizan según las reactancias de sus trayectorias.

III. III. METODOLOGÍA PROPUESTA

Basado en lo anteriormente dicho, y con el objetivo de aplicar herramientas para la rápida y eficiente localización de fallas en redes de distribución eléctrica, en este trabajo de investigación se propone un método basado en aprendizaje, precisamente el perceptrón multicapa (MLP). El MLP constituye un tipo específico de red neuronal que opera a través de múltiples capas. En este contexto, una capa de entrada es responsable de recibir las variables de entrada del problema, mientras que las capas ocultas intermedias llevan a cabo operaciones de mapeo y, finalmente, una capa de salida ofrece las predicciones o resultados deseados. Esta arquitectura se representa de manera gráfica en la Fig. 2.




Fig. 2. Arquitectura básica MLP-NN.

En esta metodología propuesta, la capa de entrada son las mediciones de las corrientes y voltajes en cabecera de los alimentadores o distribuidores de MT (media tensión) y la capa de salida sería la predicción del tipo de falla y su localización. La estrategia propuesta implica la clasificación y localización de fallas utilizando la red modelada de acuerdo con la topología de la red y los perfiles de carga. La metodología se divide principalmente en dos partes: la primera utiliza un clasificador MLP para caracterizar el tipo de falla, mientras que la segunda emplea las características extraídas por este clasificador para localizar la falla en la red.

Además, la red de distribución primaria es previamente dividida en zonas en bases a criterios significativos como ser ubicación de dispositivos de protección, longitud de la red troncal y sus derivaciones. Se sugiere dividir alimentadores extensos en varias zonas.

Para los algoritmos de clasificación del tipo de falla, impedancia de falla y localización de falla se utilizó la función de activación ReLU de la mano con el optimizador Adam por su facilidad de tratamiento de datos y poco poder de cálculos costosos en el procesamiento. Para los tres modelos se utilizó la misma cantidad de neuronas en la capa de entrada que son las mediciones de corriente y voltaje en cabecera del alimentador (nodo 799), es decir, 6 neuronas. Para el algoritmo de clasificación del tipo de falla se utilizó dos capas ocultas con 50 neuronas cada una y para la capa de salida se utilizó 4 neuronas correspondiente a las 4 etiquetas de falla. Para el algoritmo de clasificación de impedancia de falla se utilizó tres capas ocultas con 30 neuronas cada una y para la capa de salida se utilizó 10 neuronas correspondiente a las

10 etiquetas de impedancia de falla. Para el algoritmo de localización de falla se utilizó seis capas ocultas con 100 neuronas en cada capa y en la capa de salida se utilizó tres, cuatro, cinco y seis neuronas correspondientes a la red que se dividieron en tres, cuatro, cinco y seis zonas respectivamente. El valor óptimo de capas ocultas y cantidad de neuronas fue obtenido por medio de probar varias opciones utilizando la búsqueda de cuadrícula para usar la mejor combinación.

Se resumen los pasos de la metodología propuesta en el diagrama de flujo presentado en la Fig. 3.

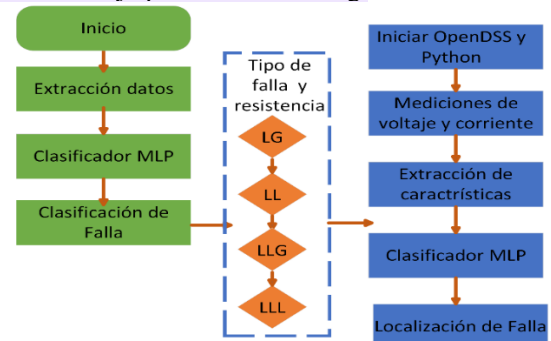


Fig. 3. Diagrama de flujo de clasificación y localización de fallas de la metodología propuesta.

Además, dependiendo del circuito de estudio o de la red de distribución donde se quiere aplicar métodos de localización de fallas, puede haber un problema de decisión porque es posible obtener diferentes ubicaciones con una misma reactancia eléctrica. Una estrategia para solventar este problema es el dividir la red de distribución y la identificación de la zona de falla usando algún método de aprendizaje [26]. Adicionalmente, con el fin de identificar la ubicación de la falla, las subzonas pueden ser establecidas por cada aparato de maniobra o protección en el sistema o incluso usando una estrategia de clasificación con un algoritmo de aprendizaje.

La base de datos contiene el tipo e impedancia de falla, así como las fases en falla (A, B o C) por lo que obtiene 3 distintas fallas monofásicas y bifásicas. Contiene 24 pasos de tiempo, 4 tipos de falla y 10 variaciones de impedancia de falla en cada nodo en que se ha simulado las fallas. Por cada falla simulada, se mide los voltajes y corrientes en cada fase en el nodo de cabecera que el nodo 799 de nuestra red de estudio. De esa manera, la base de datos es una matriz de 380,160 filas y 18 columnas, de los cuales se utilizó el 75% de los datos para entrenar y el 25% restante para validar. Se consideró variación de impedancia de falla desde 5Ω hasta 50Ω. Se observó que los resultados fueron similares para fallas LLL y LLLG por lo que se ha decidido utilizar solo las primeras. Además, no se consideran fallas de alta impedancia ya que se parte de la actuación de equipos de protección de sobrecorriente y solo se considera el análisis de una falla a la vez.

Como caso de ejemplo, se ha realizado 4 pruebas del algoritmo propuesto en 3, 4, 5 y 6 zonas respectivamente. A manera de ilustrar, se muestra la subdivisión del circuito de prueba en 3 y 4 zonas distintas, como se muestra en la Fig. 4.

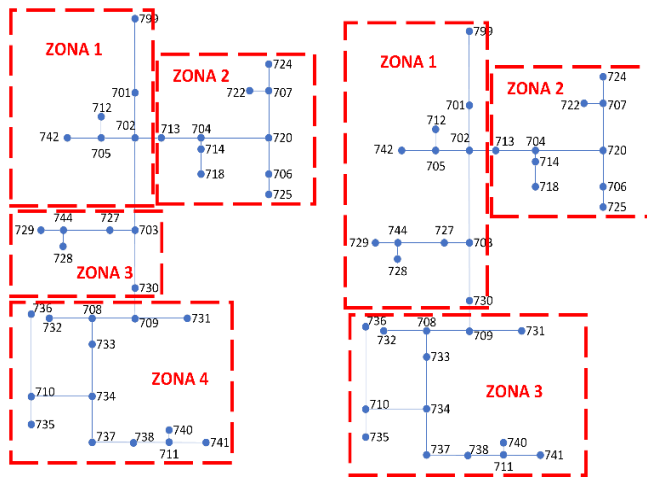


Fig. 4. División circuito de 37 barras en 3 y 4 zonas.

La metodología implementa un sistema de clasificación de tipos de fallos en un entorno eléctrico mediante MLP. Utiliza una base de datos, normaliza las características y ajusta las etiquetas de los fallos. Tras la división del conjunto de datos, se configura y entrena el MLP, cuyo progreso se monitorea a través de iteraciones adicionales. La adaptabilidad del modelo se destaca al permitir entrenamiento continuo en busca de mejoras con la optimización de parámetros. Además, los algoritmos tienen aplicaciones significativas en la monitorización y diagnóstico de sistemas eléctricos, ofreciendo una herramienta dinámica que puede adaptarse a cambios en el comportamiento del sistema a lo largo del tiempo. La capacidad de continuar el entrenamiento del modelo pre-entrenado resalta la flexibilidad y adaptabilidad de este enfoque, permitiendo la mejora continua de la precisión del modelo en situaciones del mundo real.

IV. RESULTADOS Y DISCUSIONES

Como se mencionó previamente, se someten a prueba todos los tipos de fallos en diversos buses dentro del primer sistema de evaluación, abordando una falla a la vez, seguido de la recopilación de mediciones de corriente y voltaje. Tras el entrenamiento del modelo, se exponen los resultados de predicción correspondientes a los datos de prueba. La precisión de clasificación para el clasificador propuesto alcanza valores superiores a 94%. No obstante, es evidente que la simple mención de la precisión no brinda una evaluación completa del proceso de clasificación. Para una evaluación más exhaustiva del rendimiento del modelo, es crucial tener en cuenta los resultados asociados a la matriz de confusión, así como los criterios que se derivan como ser la precisión y sensibilidad. Se muestran los resultados de la matriz de confusión tanto para la clasificación de falla en el primer esquema, así como la localización de fallas en el segundo esquema, para permitir la visualización del desempeño de nuestro algoritmo de clasificación. La matriz se organiza en filas y columnas, donde cada fila representa las instancias en una clase real y cada columna representa las instancias en una clase predicha. Los elementos diagonales de la matriz muestran predicciones

correctas para cada clase, mientras que los elementos fuera de la diagonal indican errores de clasificación.

Como se mencionó, la primera parte de la metodología es poder clasificar la falla, pudiendo reconocer y separar todos los tipos de falla. La matriz de confusión resultante de la primera parte consta de 4 filas y 4 columnas, siendo estas correspondientes a diversos tipos de fallos (LG, LL, LLG y LLL). La Fig. 5 muestra la matriz de confusión obtenida para la clasificación de los tipos de falla. El modelo se probó con un conjunto de 95,040 valores de falla, demostrando un rendimiento del 100%. Además, se observa que el modelo converge rápidamente, con pérdidas de solo 0.00113598 que nos indica la magnitud de error en cada iteración.




Fig. 5. Matriz de confusión para la clasificación del tipo de falla.

Cabe mencionar que la base de datos de falla contiene la misma cantidad de datos para las fallas LG, LL y LLG, mientras que las fallas trifásicas son menores. Se ha tratado que el modelo clasifique correctamente los tipos de falla con cantidades de datos de entrenamiento en la misma proporción que tiene la ventaja que es una base de datos equilibrada para las fallas LG, LL y LLG.

La tabla I muestra los criterios de evaluación para la clasificación del tipo de falla, notando valores en 100% para todo tipo de falla. Se muestran los criterios como sensibilidad o tasa de verdaderos positivos que mide la porción de positivos reales que fueron correctamente identificados y la Puntuación F1 que mide la media armónica entre la Precisión y la Sensibilidad.

TABLA I
CRITERIO DE EVALUACIÓN DE PREDICCIÓN PARA LA CLASIFICACIÓN DEL TIPO DE FALLA

Tipo de falla	Precisión	Sensibilidad	Puntuación F1	Soporte
LG	1	1	1	25979
LL	1	1	1	25898
LLN	1	1	1	25817
LLL	1	1	1	17346

Además, se muestra la evolución de la pérdida del modelo durante el entrenamiento de múltiples iteraciones con los datos de

18

entrenamiento dados, y se comparan con los datos de validación para mostrar el rendimiento del modelo con los ajustes de datos nuevos. Esta relación se muestra en la Fig. 6. Se muestran pérdidas bajas con una convergencia rápida del modelo, lo que indica un buen ajuste de los parámetros del modelo MLP.




Fig. 6. Pérdida del modelo para la clasificación del tipo de falla

La tabla II muestra los criterios de evaluación para la clasificación de la resistencia de falla, observando valores superiores al 95% de precisión.

TABLA II
CRITERIO DE EVALUACIÓN DE PREDICCIÓN PARA LA
CLASIFICACIÓN DE RESISTENCIA DE FALLA

Resistencia de falla	Precisión	Sensibilidad	Puntuación F1	Soporte
5	0.99	0.98	0.98	9670
10	0.97	0.97	0.97	9480
15	0.98	0.97	0.97	9398
20	0.97	0.97	0.97	9469
25	0.97	0.97	0.97	9502
30	0.97	0.96	0.97	9482
35	0.96	0.96	0.96	9413
40	0.96	0.96	0.96	9585
45	0.95	0.96	0.96	9442
50	0.98	0.96	0.97	9670

La segunda parte del modelo es precisamente localizar la falla antes clasificada, es decir, con las características extraídas de la primera parte del modelo para ser entrenado en la localización en la red de prueba. Como muestra de los resultados obtenidos, se ha hecho el procedimiento con el circuito de prueba dividido en 5 zonas obteniendo valores. La Fig.7 muestra la matriz de confusión para un circuito de prueba separado en 5 zonas, es

decir, tendremos una matriz de 5x5, uno por cada zona.




Fig. 7. Matriz de confusión para la localización de falla en división de 5 zonas.

Además, se muestra la evolución de la pérdida del modelo durante el entrenamiento de múltiples iteraciones con los datos de entrenamiento dados, y se comparan con los datos de validación para mostrar el rendimiento del modelo con los ajustes de datos nuevos. Esta relación se muestra en la Fig. 8.




Fig. 8. Pérdida del modelo para la clasificación de localización de fallas.

En la Tabla III, donde se comprueba alto valores de precisión en la localización de fallas, también se muestran otros criterios de evaluación en la predicción alto rendimiento, como la sensibilidad o recuperación. Esta etapa del modelo logra converger en muchas más iteraciones comparado con la convergencia de la primera parte del modelo.

TABLA III
CRITERIO DE EVALUACIÓN DE PREDICCIÓN PARA LA
LOCALIZACIÓN DE FALLA.

Zona	Precisión	Sensibilidad	Puntuación F1	Soporte
z1	0.82	0.81	0.86	3175
z2	0.82	0.83	0.82	5321
z3	0.82	0.86	0.84	3176

z4	0.85	0.86	0.85	3143
z5	0.94	0.98	0.96	4193

Además, la Fig. 9 nos muestra las curvas ROC, que maximiza la tasa de verdaderos positivos mientras se minimza la tasa de falsos positivos, en donde se muestra un área bajo la curva cercano a 1, lo cual indica una correcta clasificación entre las zonas en falla.




Fig. 9. Curvas ROC para las clases de zonas en falla.

La curva precisión -sensibilidad muestra la compensación entre la precisión y sensibilidad para diferentes umbrales. Un área bajo la curva con valores cercanos a 1 representa un alto recuerdo como una alta precisión. La Fig. 10 muestra la relación entre la precisión y la sensibilidad, cuya área bajo la curva es cercano a 1, lo que indica resultados correctos en la predicción de las zonas en falla.

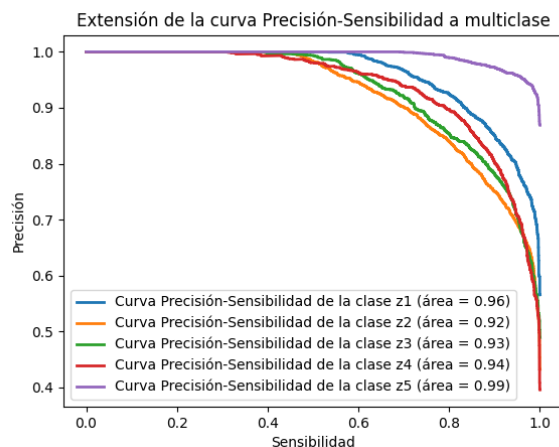


Fig. 10. Relación precisión-sensibilidad para las zonas en falla.

Los resultados de la predicción de la localización de las fallas simuladas se han obtenidos a partir de los cuatro ejemplos de subdivisiones de 3, 4, 5 y 6 zonas distintas que se denotan como caso 1, 2, 3 y 4. Como puede observarse, los resultados son precisos dando valores superiores al 88% de exactitud y pueden variar poco de acuerdo con el modelo de división de zonas a tomar. El resumen de los criterios de evaluación del modelo

propuesto se muestra en la Tabla IV.

El modelo propuesto no ha considerado condiciones de fallas simultáneas ni de alta impedancia, ya que la premisa es sobre la actuación de equipos de protección de sobrecorriente el cual no detecta las fallas de alta impedancia. A su vez, en trabajo futuros se planea agregar ambas condiciones y la inserción generación fotovoltaica.

TABLA IV
PRECISIÓN PARA LOS CUATRO CASOS DE PRUEBA EN LA LOCALIZACIÓN DE FALLAS

	Caso 1	Caso 2	Caso 3	Caso 4
Zona	Precisión			
z1	0.85	0.81	0.89	0.81
z2	0.81	0.80	0.84	0.82
z3	0.93	0.92	0.82	0.80
z4		0.89	0.81	0.84
z5			0.91	0.82
z6				0.87

VI. CONCLUSIONES

Se ha presentado el uso de herramientas de aprendizaje como redes neuronales artificiales para el problema de localización de fallas en redes de distribución a partir de mediciones de corriente y voltaje en alimentadores de MT. Simulaciones de falla (LG, LL, LLG, LLL y LLLG) se han realizado en OpenDSS en el circuito de prueba IEEE 37-bus feeder, variando la resistencia de falla y midiendo valores en el alimentador de cabecera. Se ha descrito la importancia de esta poderosa herramienta en comparación con los modelos tradicionales para la detección y localización de fallas. Se ha comprobado la utilidad de MLP en la clasificación de tipos de falla, impedancia de falla y localización de estas con respecto a varios factores de simulación. Se han obtenido resultados de precisión superiores del 90% y hemos notado que una correcta división de zonas aumenta el rendimiento y los criterios de evaluación en el problema de localización de fallas en redes de distribución radiales.

Se propone la división de zonas en la red de distribución para evitar el problema de múltiple estimación de localización de fallas. Y con este enfoque se contribuye a la localización de fallas en redes de distribución.

IV. AGRADECIMIENTOS

El autor expresa su sincero agradecimiento al DAAD y al Instituto de Energía Eléctrica de la Universidad de San Juan, Argentina, por su invaluable apoyo económico y académico, fundamental para el desarrollo de este trabajo.

REFERENCIAS

- [1] M. Gholami, A. Abbaspour, M. Moeini-Agtaie, M. Fotuhi-Firuzabad, and M. Lehtonen, "Detecting the Location of Short-Circuit

Faults in Active Distribution Network Using PMU-Based State Estimation," IEEE Trans Smart Grid, vol. 11, no. 2, pp. 1396–1406, Mar. 2020, doi: 10.1109/TSG.2019.2937944.

[2] A. N. Samudrala, M. H. Amini, S. Kar, and R. S. Blum, "Distributed Outage Detection in Power Distribution Networks," IEEE Trans Smart Grid, vol. 11, no. 6, pp. 5124–5137, Nov. 2020, doi: 10.1109/TSG.2020.2999921.

[3] R. Kumar and D. Saxena, "Fault location in distribution network with distributed generation: An overview and key issues," in 2016 IEEE 7th Power India International Conference, PIICON 2016, Institute of Electrical and Electronics Engineers Inc., Oct. 2017, doi: 10.1109/POWERI.2016.8077473.

[4] S. Ahmad and A. U. Asar, "Reliability enhancement of electric distribution network using optimal placement of distributed generation," Sustainability (Switzerland), vol. 13, no. 20, Oct. 2021, doi: 10.3390/su132011407.

[5] M. Weiss et al., "División de Energía," 2021. [Online]. Available: <http://www.iadb.org>

[6] F. G. Y. Souhe, A. T. Boum, P. Ele, C. F. Mbey, and V. J. F. Kakeu, "Fault Detection, Classification And Location In Power Distribution Smart Grid Using Smart Meters Data," Journal of Applied Science and Engineering (Taiwan), vol. 26, no. 1, pp. 23–34, 2022, doi: 10.6180/jase.202301_26(1).0003.

[7] A. Zidan et al., "Fault Detection, Isolation, and Service Restoration in Distribution Systems: State-of-the-Art and Future Trends," IEEE Trans Smart Grid, vol. 8, no. 5, pp. 2170–2185, Sep. 2017, doi: 10.1109/TSG.2016.2517620.

[8] S. S. Gururajapathy, H. Mokhlis, and H. A. Illias, "Fault location and detection techniques in power distribution systems with distributed generation: A review," 2017, Elsevier Ltd. doi: 10.1016/j.rser.2017.03.021.

[9] A. Ghaderi, H. L. Ginn, and H. A. Mohammadpour, "High impedance fault detection: A review," Feb. 01, 2017, Elsevier Ltd. doi: 10.1016/j.epr.2016.10.021.

[10] J. Cordova and M. O. Faruque, "Fault Location Identification in Smart Distribution Networks with Distributed Generation."

[11] A. Zidan et al., "Fault Detection, Isolation, and Service Restoration in Distribution Systems: State-of-the-Art and Future Trends," IEEE Trans Smart Grid, vol. 8, no. 5, pp. 2170–2185, Sep. 2017, doi: 10.1109/TSG.2016.2517620.

[12] A. Mohamed, T. Lamhamdi, H. El Moussaoui, and H. El Markhi, "A multi-agent system for fault location and service restoration in power distribution systems," Multiagent and Grid Systems, vol. 15, no. 4, pp. 343–358, 2019, doi: 10.3233/MGS-190316.

[13] I. Srivastava, S. Bhat, B. V. S. Vardhan, and N. D. Bokde, "Fault Detection, Isolation and Service Restoration in Modern Power Distribution Systems: A Review," Oct. 01, 2022, MDPI. doi: 10.3390/en15197264.

[14] R. A. Sevlian, Y. Zhao, R. Rajagopal, A. Goldsmith, and H. V. Poor, "Outage Detection Using Load and Line Flow Measurements in Power Distribution Systems," in IEEE Transactions on Power Systems, Institute of Electrical and Electronics Engineers Inc., Mar. 2018, pp. 2053–2069. doi: 10.1109/TPWRS.2017.2727979.

[15] J. Tavoosi, M. Shirkhani, A. Azizi, S. Ud Din, A. Mohammadzadeh, and S. Mobayen, "A hybrid approach for fault location in power distributed networks: Impedance-based and machine learning technique," Electric Power Systems Research, vol. 210, Sep. 2022, doi: 10.1016/j.epr.2022.108073.

[16] R. Dashti, M. Ghasemi, and M. Daisy, "Fault location in power distribution network with presence of distributed generation

resources using impedance based method and applying Π line model," Energy, vol. 159, pp. 344–360, Sep. 2018, doi: 10.1016/j.energy.2018.06.111.

[17] A. Mohamed, T. Lamhamdi, H. El Moussaoui, and H. El Markhi, "A multi-agent system for fault location and service restoration in power distribution systems," Multiagent and Grid Systems, vol. 15, no. 4, pp. 343–358, 2019, doi: 10.3233/MGS-190316.

[18] D. S. Gazzana et al., "An integrated technique for fault location and section identification in distribution systems," Electric Power Systems Research, vol. 115, pp. 65–73, 2014, doi: 10.1016/j.epr.2014.02.002.

[19] Z. Jianwen, H. Hui, G. Yu, H. Yongping, G. Shuping, and L. Jianan, "Single-phase ground fault location method for distribution network based on traveling wave time-frequency characteristics," Electric Power Systems Research, vol. 186, Sep. 2020, doi: 10.1016/j.epr.2020.106401.

[20] S. Myint and W. Wichakool, "A simple faulted phase-based fault distance estimation algorithm for a loop distribution system," Indonesian Journal of Electrical Engineering and Computer Science, vol. 25, no. 1, pp. 14–24, Jan. 2022, doi: 10.11591/ijeecs.v25.i1.pp14-24.

[21] L. Xie, L. Luo, Y. Li, Y. Zhang, and Y. Cao, "A Traveling Wave-Based Fault Location Method Employing VMD-TEO for Distribution Network," IEEE Transactions on Power Delivery, vol. 35, no. 4, pp. 1987–1998, Aug. 2020, doi: 10.1109/TPWRD.2019.2959188.

[22] A. Bahmanyar, S. Jamali, A. Estebarsari, and E. Bompard, "A comparison framework for distribution system outage and fault location methods," Apr. 01, 2017, Elsevier Ltd. doi: 10.1016/j.epr.2016.12.018.

[23] A. Ghaemi, A. Safari, H. Afsharirad, and H. Shayeghi, "Accuracy enhance of fault classification and location in a smart distribution network based on stacked ensemble learning," Electric Power Systems Research, vol. 205, Apr. 2022, doi: 10.1016/j.epr.2021.107766.

[24] S. Jamali, A. Bahmanyar, and S. Ranjbar, "Hybrid classifier for fault location in active distribution networks," Protection and Control of Modern Power Systems, vol. 5, no. 1, Dec. 2020, doi: 10.1186/s41601-020-00162-y.

[25] D. Thukaram, H. P. Khincha, and H. P. Vijaynarasimha, "Artificial neural network and support vector machine approach for locating faults in radial distribution systems," IEEE Transactions on Power Delivery, vol. 20, no. 2 I, pp. 710–721, Apr. 2005, doi: 10.1109/TPWRD.2005.844307.

[26] J. Mora-Flórez, G. Morales-España, and S. Pérez-Londoño, "Learning-based strategy for reducing the multiple estimation problem of fault zone location in radial power systems," IET Generation, Transmission and Distribution, vol. 3, no. 4, pp. 346–356, 2009, doi: 10.1049/iet-gtd.2008.0164.