

CONESCAPANHONDURAS2025paper145.pdf

 Institute of Electrical and Electronics Engineers (IEEE)

Document Details

Submission ID

trn:oid:::14348:477744008

Submission Date

Jul 31, 2025, 9:52 PM CST

Download Date

Aug 12, 2025, 6:33 PM CST

File Name

CONESCAPANHONDURAS2025paper145.pdf

File Size

494.3 KB

5 Pages




3,187 Words

18,655 Characters

9% Overall Similarity

The combined total of all matches, including overlapping sources, for each database.

Top Sources

- 9%  Internet sources
- 6%  Publications
- 0%  Submitted works (Student Papers)

Integrity Flags




0 Integrity Flags for Review

No suspicious text manipulations found.

Our system's algorithms look deeply at a document for any inconsistencies that would set it apart from a normal submission. If we notice something strange, we flag it for you to review.

A Flag is not necessarily an indicator of a problem. However, we'd recommend you focus your attention there for further review.

Top Sources

- 9%  Internet sources
- 6%  Publications
- 0%  Submitted works (Student Papers)

Top Sources

The sources with the highest number of matches within the submission. Overlapping sources will not be displayed.

1	Internet	alife-robotics.co.jp	1%
2	Internet	www.ijisae.org	1%
3	Publication	Ayan Paul, Rajendra Machavaram. "Advancing Capsicum Detection in Night-Time ...	1%
4	Internet	astraeitorialshop.com	<1%
5	Internet	www.proceedings.com	<1%
6	Internet	www.mdpi.com	<1%
7	Internet	www.researchgate.net	<1%
8	Internet	ijadst.com	<1%
9	Internet	sedici.unlp.edu.ar	<1%
10	Internet	journalagroeco.org.ua	<1%
11	Internet	tesis.ipn.mx	<1%

12	Internet	rehip.unr.edu.ar	<1%
13	Internet	www.revespcardiol.org	<1%
14	Publication	Andres Esteban Puerto Lara, Cesar Pedraza, David A. Jamaica-Tenjo. "chapter 9 W...	<1%
15	Internet	academica-e.unavarra.es	<1%
16	Internet	biblat.unam.mx	<1%
17	Internet	hrcak.srce.hr	<1%

Computer Vision for Weed Detection in Radish Crops in Honduras: Towards Selective Herbicide Application

Abstract—The agricultural sector is a key pillar of Honduras' economy and food security. However, local crop systems suffer from productivity losses due to pests, diseases, and weed competition. Conventional practices based on the indiscriminate use of agrochemicals increase costs and environmental damage while promoting herbicide resistance. This research proposes a computer vision-based weed detection system trained with a custom dataset generated through manual radish cultivation. Images were annotated and preprocessed using the Roboflow 3.0 platform, including data augmentation techniques such as resizing (640x640), and brightness, saturation, and exposure adjustments. Three training iterations were conducted using YOLO-based models, with version 3 (v3) achieving the best results. Under a confidence threshold of 20%, v3 showed a sensitivity of 94% and specificity of 96%, demonstrating the model's high accuracy under variable lighting conditions. These findings validate the potential of the approach to optimize herbicide use and reduce its environmental impact. The system shows promise for integration into future smart spraying robots, enhancing precision agriculture practices in Honduras and offering a scalable solution adaptable to crops such as corn, beans, and coffee.

Keywords—Agriculture, Computer Vision, Deep Learning, Herbicide Reduction, Honduras, Object Detection, Precision Agriculture, Roboflow, Smart Farming, Weed Detection.

I. INTRODUCCIÓN

El cultivo de rábano (*Raphanus sativus* L.), una hortaliza de ciclo corto ampliamente cultivada en regiones tropicales y subtropicales, representa un componente esencial para la seguridad alimentaria y la diversificación agrícola debido a su alto valor nutricional, rapidez de cosecha y demanda creciente en mercados locales e internacionales [1]. La versatilidad del rábano para adaptarse a distintos tipos de suelo, desde arenosos hasta franco-arenosos con buen drenaje y pH entre 5.5 y 6.8, ha permitido su expansión en diversas zonas agroecológicas [1], [2]. No obstante, pese a su aparente rusticidad, el cultivo enfrenta serios desafíos fitosanitarios que comprometen tanto la cantidad como la calidad de la producción.

Diversos estudios han documentado que el rábano es altamente susceptible a plagas como la mosca sierra (*Athalia lugens proxima*), el taladro del repollo (*Hellula undalis*) y la chinche pintada (*Bagrada cruciferarum*), cuyas larvas y adultos deterioran severamente hojas y tallos, reduciendo la fotosíntesis y debilitando las plantas [1]. De igual forma, enfermedades fúngicas como la roya blanca (*Albugo candida*), el tizón por *Alternaria raphani* y la pudrición radicular bacteriana causada por *Erwinia rhapontici* son responsables de pérdidas económicas considerables [1]. Estas patologías no solo reducen el

rendimiento, sino que deterioran la calidad comercial de la raíz, disminuyendo su aceptación en el mercado. Las estrategias convencionales para mitigar estos problemas se han basado principalmente en el uso intensivo de fungicidas, insecticidas y rotación de cultivos [1], prácticas que, aunque efectivas en el corto plazo, implican altos costos económicos, riesgos ambientales y la potencial generación de resistencia en patógenos y plagas.

Por otro lado, la competencia con malezas constituye un desafío adicional. Las malezas no solo reducen la disponibilidad de nutrientes y agua, sino que sirven como reservorios para insectos y fitopatógenos, dificultando el manejo integrado del cultivo. En sistemas tradicionales, el control se realiza mediante escardas manuales o aplicaciones generalizadas de herbicidas, métodos que incrementan el consumo de recursos y pueden afectar negativamente a las propias plántulas del cultivo por falta de selectividad.

La incorporación de herramientas tecnológicas innovadoras, como la inteligencia artificial (IA) aplicada al reconocimiento de imágenes, ofrece una oportunidad para superar estas limitaciones. Sin embargo, aunque existen investigaciones sobre automatización agrícola centradas en sensores de humedad, sistemas de fertirrigación y vigilancia ambiental, son escasos los estudios que implementen algoritmos de visión computarizada entrenados específicamente para diferenciar hojas de rábano y malezas en campo abierto, con el fin de aplicar herbicidas de manera selectiva y precisa. Esta ausencia de discriminación ha sido una de las principales carencias en desarrollos previos, que continúan utilizando la aplicación uniforme de químicos sin una identificación visual robusta del objeto a tratar.

El presente proyecto aborda precisamente esa brecha, al diseñar e implementar un sistema de control automatizado del cultivo de rábanos que integra IA mediante la plataforma Roboflow para el entrenamiento de modelos personalizados capaces de distinguir entre hoja de rábano y malezas en tiempo real. Así, se posibilita la aplicación dirigida de herbicida, reduciendo el uso innecesario de agroquímicos, protegiendo las plántulas del cultivo y contribuyendo a la sostenibilidad ambiental. Además, se realizaron dos ciclos completos de cultivo que permitieron validar experimentalmente la importancia del manejo fitosanitario: en el primer ciclo, con la aplicación adecuada de fertilizantes, fungicidas y pesticidas, se cosecharon 368 rábanos saludables en 32 días; mientras que, en

el segundo ciclo, sin intervención química, pero con igual calidad de suelo y riego, la cosecha se extendió a casi 50 días y se redujo a 182 rábanos, muchos afectados por hongos y plagas. Estos resultados preliminares proporcionan evidencia concreta del impacto que tiene el manejo controlado sobre la productividad y sirven de fundamento para demostrar la relevancia del sistema propuesto.

De esta manera, esta investigación aporta un valor añadido significativo, al no solo automatizar procesos agrícolas, sino incorporar una capa de inteligencia visual que optimiza el uso de insumos, mejora la eficiencia productiva y responde a las crecientes demandas de prácticas agrícolas sostenibles. Con ello, se avanza hacia un modelo más preciso, responsable y económicamente viable para el cultivo del rábano, abriendo nuevas perspectivas para su replicación en otros cultivos hortícolas.

II. REVISIÓN DE LA LITERATURA

La incorporación de inteligencia artificial (IA) y visión por computadora en la agricultura representa un avance importante para el manejo de plagas y malezas. Tradicionalmente, la aplicación uniforme de herbicidas ha sido la práctica más común, aunque esto implica altos costos económicos, daños al medio ambiente y poca eficiencia debido a que no siempre se aplican en el lugar correcto [2]. Sin embargo, los avances en algoritmos de “Deep Learning” permiten crear modelos que distinguen con precisión entre las hojas de los cultivos y las malezas en condiciones reales de campo, mejorando así el monitoreo y control [3].

El uso de redes neuronales convolucionales (CNN) ha mostrado buenos resultados en cultivos como trigo, algodón y cebada, con niveles de precisión superiores al 90 % cuando se cuenta con suficientes datos bien organizados para entrenarlas [4]. Estos modelos pueden superar el problema conocido como “Green on Green”, que es cuando es difícil distinguir a simple vista las malezas porque se parecen mucho a los cultivos en color y forma [5].

Un paso adelante en esta tecnología es el desarrollo de robots que aplican herbicidas solo sobre las malezas. Estos dispositivos usan cámaras y sensores junto con programas que detectan las malezas para reducir el uso total de químicos sin perder efectividad [6]. En estudios de campo, estos robots han logrado reducir el uso de herbicidas entre un 35 % y un 70 %, lo que representa beneficios económicos y ambientales importantes [5].

Además, la resistencia creciente de las malezas a los herbicidas comunes se ha convertido en un problema mundial. El uso prolongado de los mismos químicos ha creado la necesidad de implementar un manejo integrado que combine biotecnología, robótica y tecnología digital, con el objetivo de hacer la agricultura más sostenible [7]. Este cambio implica que las soluciones futuras deben ser interdisciplinarias, flexibles y enfocadas en controlar las malezas de forma estratégica, en lugar de eliminarlas por completo [7].

En la agricultura de precisión se usan tecnologías de imágenes y aprendizaje automático en diferentes niveles. A gran escala, las imágenes satelitales de alta calidad junto con

programas inteligentes permiten identificar y controlar malezas en grandes áreas, ayudando a tomar mejores decisiones con mucha información [6]. Por otro lado, a nivel local, las cámaras que se ponen directamente en los robots agrícolas, junto con modelos de aprendizaje automático, pueden detectar y controlar malezas en tiempo real dentro del cultivo. Esta forma de trabajar ayuda a usar menos herbicidas y a mejorar el control de malezas.

En cuanto a los robots agrícolas, un estudio reciente presentó un robot con cuatro ruedas motrices (4WD) que utiliza un modelo de aprendizaje profundo para detectar cintas de riego, surcos, cultivos sanos y enfermos, así como malezas, con niveles de precisión entre 83 % y 99 % [8]. Este robot tiene un método novedoso para calcular el ángulo por donde debe moverse, lo que ayuda a evitar daños a las plantas y a controlar el movimiento de forma precisa a velocidades bajas de 12.5 cm/s.

Durante las pruebas de aplicación de herbicidas, ajustar el tiempo de activación del rociador según la velocidad del robot permitió alcanzar una tasa de cobertura efectiva de malezas del 83 % y una reducción del 53 % en el uso de pesticidas, manteniendo baja la cobertura ineficaz (8 %) [8]. Sin embargo, cuando el robot va más rápido, la precisión disminuye y la efectividad del control baja. Además, algunos cultivos enfermos pequeños pueden no ser rociados correctamente, incluso cuando el sistema está bien ajustado [8], [9].

Estos resultados muestran la importancia de seguir mejorando los sistemas de control y los modelos de visión para que los robots agrícolas sean más eficientes y puedan usarse en diferentes cultivos, especialmente en situaciones donde es fundamental ahorrar recursos.

III. METODOLOGÍA

El desarrollo de este estudio se enfocó en la implementación de un sistema de visión por computadora para la detección de malezas en cultivos de rábano. A diferencia de trabajos similares como los presentados en [10] y [11], en los que se utilizaron conjunto de datos públicos o imágenes aéreas, en esta investigación se optó por la generación de un conjunto de datos propio, lo que permite adaptar el sistema a las condiciones reales y específicas del contexto agrícola hondureño

A. Generación del Conjunto de Datos

Con el fin de contar con un conjunto de datos representativo y personalizado, se llevó a cabo el cultivo manual de rábanos en una parcela experimental. Durante las diferentes etapas del crecimiento de los cultivos, se tomaron fotografías utilizando cámaras convencionales, aproximadamente a 120 centímetros de altura, garantizando variedad en iluminación, ángulos y condiciones ambientales. Este proceso fue clave para capturar tanto las plantas de rábano como la presencia natural de malezas locales, lo cual garantiza una mayor relevancia del modelo para su futura aplicación en campo.



Fig. 1. Fotografía tomada en la parcela experimental.

B. Anotación y Preprocesamiento en Roboflow

Una vez recolectadas las imágenes, se utilizó la plataforma Roboflow 3.0 para la anotación de los datos. Cada imagen fue etiquetada manualmente para clasificar los objetos presentes en las categorías de "rábano" y "maleza", siguiendo una estructura similar a la utilizada en trabajos como [12].

Para estandarizar los datos y mejorar la eficiencia del entrenamiento, se aplicaron procesos de preprocesamiento y aumentación dentro de la misma plataforma: Redimensionado de todas las imágenes a 640x640 píxeles. Aumentaciones automáticas: Saturación: $\pm 25\%$ Brillo: $\pm 15\%$ Exposición: $\pm 10\%$

Estas técnicas buscan aumentar la generalización del modelo frente a variaciones comunes en ambientes agrícolas, tal como lo sugiere [11].

C. Entrenamiento de los Modelos

Se realizaron tres iteraciones de entrenamiento utilizando los modelos base de Roboflow 3.0 y YOLO (You Only Look Once), una arquitectura ampliamente probada en aplicaciones agrícolas por su precisión y velocidad de inferencia en tiempo real [8]. Los modelos se entrenaron directamente desde Roboflow utilizando su función de entrenamiento automático con ajuste de hiperparámetros y monitoreo de desempeño.

IV. RESULTADOS

Tras completar las tres iteraciones de entrenamiento descritas en la metodología, el modelo versión 3 (v3) fue seleccionado para la fase de evaluación final debido a sus métricas superiores en comparación con las versiones anteriores. Este modelo alcanzó una precisión media promedio a un umbral de confianza de 50% de 36.4 %, una precisión general de 45.5 % y una recuperación de 40.2 %. No obstante, se realizó una evaluación más detallada utilizando el modelo v3 aplicado directamente sobre nuevas imágenes de prueba, simulando las condiciones operativas del sistema.

Durante esta fase, se ajustó el parámetro de confianza a un umbral bajo del 20 %. Este valor se estableció con el fin de maximizar la detección de malezas, incluso en casos donde la probabilidad asignada por el modelo no fuese alta, permitiendo así evaluar la sensibilidad del sistema en escenarios reales. Como resultado de este ajuste, se observó un aumento significativo en la tasa de detecciones correctas.



Fig. 2. Resultado de simulación del modelo v3 con un umbral de confianza del 20%.

TABLE I. TABLA DE RESULTADOS DEL MODELO V3

Análisis de Detección de malezas y cultivos			
Plantas detectadas como cultivos	Positivo Verdadero	Positivo Falso	PPV
	86	4	0.95
Plantas detectadas como malezas	Negativo Falso	Negativo Verdadero	NPV
	5	99	0.95
Resultados	Sensibilidad	Especificidad	
	0.94	0.96	

Con el umbral de confianza al 20 %, el modelo v3 alcanzó una sensibilidad de del 94% en la identificación de objetos plantas identificadas como cultivos. Este resultado indica que, a pesar de los valores moderados de precisión media promedio y recuperación obtenidos durante el entrenamiento, el sistema tiene la capacidad de ejecutar detecciones altamente precisas cuando se optimiza adecuadamente su configuración. Este comportamiento es consistente con lo reportado en estudios similares, donde modelos YOLO alcanzan su mejor desempeño tras ajustes finos en los parámetros de inferencia.

En la práctica, esta alta precisión se traduce en una capacidad confiable para detectar malezas en imágenes del cultivo de rábano, lo que abre la posibilidad de utilizar este modelo como base funcional para una futura integración en sistemas robóticos de aplicación selectiva de herbicidas. Además, la efectividad del modelo en condiciones visuales variables reafirma el valor de las técnicas de aumento de datos y preprocesamiento implementadas en la fase de entrenamiento. Estos resultados refuerzan la viabilidad técnica del enfoque propuesto y respaldan su potencial aplicación en la agricultura de precisión en Honduras.

V. CONCLUSIONES

La presente investigación demuestra que la metodología basada en visión por computadora para la detección de malezas en cultivos de rábano es técnicamente viable, precisa y adaptable a condiciones reales de campo. A través del entrenamiento de modelos en la plataforma Roboflow con una base de datos

personalizada, se logró un sistema con una sensibilidad del 94 % y una especificidad del 96 %, cifras que indican un alto grado de confiabilidad en la clasificación de cultivos y malezas en imágenes reales.

El modelo versión 3 (v3), ajustado a un umbral de confianza del 20 %, alcanzó un desempeño sobresaliente, siendo capaz de detectar malezas con una precisión del 94%. Estos resultados posicionan a este enfoque como una solución funcional que puede ser aplicada en otros cultivos estratégicos para Honduras, tales como maíz, arroz, frijoles y soya y la flexibilidad de los modelos YOLO y las técnicas de aumentación empleadas permiten su escalabilidad a distintos entornos agrícolas, tanto en pequeña como en gran escala.

Asimismo, la literatura especializada respalda el impacto económico y ambiental de esta tecnología. Estudios recientes indican que la aplicación selectiva de herbicidas mediante visión artificial puede reducir el uso total de productos químicos entre un 34.5 % y un 53 % en diferentes cultivos [8], [9]. Por tanto, el desarrollo de sistemas inteligentes como el aquí propuesto no solo mejora la eficiencia del manejo de malezas, sino que contribuye a una agricultura más sostenible y competitiva para el país.

VI. TRABAJO FUTURO

Si bien el presente proyecto ha demostrado la viabilidad de un sistema automatizado para el reconocimiento y diferenciación de cultivos y malezas mediante inteligencia artificial, el trabajo no concluye aquí. Como extensión natural, se plantea la integración del modelo de visión computarizada desarrollado —entrenado con Roboflow para distinguir hojas de cultivo frente a malezas— en un vehículo autónomo equipado con cámaras y un módulo de procesamiento basado en Raspberry Pi. Este robot recorrerá de forma autónoma los surcos agrícolas, identificará las malezas en tiempo real y aplicará herbicidas de manera dirigida únicamente sobre ellas, maximizando la selectividad y reduciendo el uso indiscriminado de agroquímicos.

Este enfoque permitirá validar en condiciones reales el desempeño del modelo entrenado, así como cuantificar el ahorro en insumos, tiempo y mano de obra respecto a métodos manuales o a aplicaciones generalizadas de herbicidas. La propuesta se alinea con investigaciones previas que han implementado bots inteligentes con visión artificial para detectar y eliminar malezas, como el “Smart Weed Detection and Removal Bot (SWDRB)” en cultivos hortícolas [13]. No obstante, estos estudios se han centrado principalmente en la etapa de identificación, sin avanzar hacia una integración plena con vehículos autónomos que ejecuten la acción correctiva in situ en el contexto de cultivos esenciales para Honduras, como maíz, frijoles y café.




Fig. 3. Diseño de módulos de recolección y procesamiento de imágenes.




Fig. 4. Diseño de prototipo de riego en Solidworks.

El futuro del proyecto contempla el diseño y construcción de este vehículo agrícola autónomo, así como la ejecución de experimentos controlados en parcelas piloto para evaluar métricas clave como la precisión en la identificación de malezas, el volumen de herbicida utilizado, el ahorro económico y el tiempo operativo en comparación con los métodos tradicionales. Este desarrollo no solo reforzará la aplicabilidad práctica del sistema propuesto, sino que abrirá oportunidades para replicarlo en distintos cultivos y escalas productivas, consolidándose como un paso relevante hacia una agricultura de precisión más sostenible, tecnificada y adaptada a las necesidades de la región.

REFERENCIAS

- [1] R. Selvakumar et al., "Scientific Management of Pests and Diseases in Radish Cultivation," *Indian Farmer*, vol. 6, no. 3, pp. 198–202, Mar. 2019.
- [2] Xie, Z., Li, J., & Huang, Y. (2020). Development of an intelligent sprayer using 3D sensing for site-specific herbicide application. *Computers and Electronics in Agriculture*, 173, 105386.
- [3] Grinblat, G. L., Giménez, M. A., & Petisco, J. (2023). Deep learning-based detection of crop and weed species in cereal fields using CNNs. *Computers and Electronics in Agriculture*, 208, 107896.
- [4] Perez, L. M., Carrillo, F. J., & Silva, R. T. (2022). Computer vision for weed recognition in cotton crops: Challenges and advances. *Computers and Electronics in Agriculture*, 196, 106899.
- [5] Zhou, H., Yang, L., & Wang, X. (2023). Deep learning-based semantic segmentation for robotic herbicide application. *Computers and Electronics in Agriculture*, 204, 107613.
- [6] Rodriguez-Lizana, A., et al. (2023). Mapping weed management methods in orchards using Sentinel-2 imagery and machine learning. *Smart Agricultural Technology*, 5, 100179.

- 4
 - 1
 - 6
 - 7
 - 5
 - 8
 - 3
- [7] Buhler, D. D., Young, B. G., & Bhowmik, P. C. (2023). Weed management in 2050: Perspectives on the future of weed science. *Weed Science*, 71(2), 135-146.
- [8] Huang, Y., Zhang, Z., & Li, X. (2024). Robust Guidance and Selective Spraying Based on Deep Learning for an Advanced Four-Wheeled Farming Robot. *Agriculture*, 14(1), 57.
- [9] S. Fennimore, M. Slaughter, H. Siemens, S. Foix, and N. Taberner, "Technology for automation of weed control in specialty crops," *Weed Technology*, vol. 30, no. 4, pp. 823–837, Oct. 2016.
- [10] S. M. D. P. Vaideeswar, C. V. R. Reddy and M. B. Tavares, "Weed Detection: A Vision Transformer Approach For Soybean Crops," *2023 14th International Conference on Computing Communication and Networking Technologies (ICCCNT)*, Delhi, India, 2023, pp. 1-8, doi: 10.1109/ICCCNT56998.2023.10307069.
- [11] S. B. K. K. A. Shenoy, M. R. Jain and M. K., "Detecting Crops and Weeds in Fields Using YOLOv6 and Faster R-CNN Object Detection Models," *2023 International Conference on Recent Advances in Information Technology for Sustainable Development (ICRAIS)*, Manipal, India, 2023, pp. 43-48, doi: 10.1109/ICRAIS59684.2023.10367086.
- [12] A. J. Irías Tejeda and R. Castro Castro, "Algorithm of Weed Detection in Crops by Computational Vision," *2019 International Conference on Electronics, Communications and Computers (CONIELECOMP)*, Cholula, Mexico, 2019, pp. 124-128, doi: 10.1109/CONIELECOMP.2019.8673182.
- [13] R. Praveenraj, R. Ramya, S. Thanu and R. Aswinkumar, "Computer Vision based Smart Bot for Weed Detection and Removal in Vegetable Crop Fields," *2024 International Conference on Inventive Computation Technologies (ICICT)*, Lalitpur, Nepal, 2024, pp. 919-924, doi: 10.1109/ICICT60155.2024.10544594.